

תסריט להקלטה למחברת 1: בייסאני מול קלאסי, אחוזי הצלחה בבתי ספר

משך משוער: כ-33-38 דקות בהקלטה בפועל (קריאה בקצב בינוני, ללא זמן המתנה על ריצת תאים).

פתיחה

במחברת הזאת אני עושה ניתוח בייסאני מול קלאסי של פרופורציות, כלומר "כמה אחוז מתוך קבוצה מצליחים במשהו".

השאלה שחוזרת לאורך כל המחברת פשוטה: מהו אחוז ההצלחה האמיתי של קבוצה נתונה, ואיך אומדים אותו מתוך הנתונים שיש? הרעיון המרכזי הוא לענות על השאלה הזו בשתי גישות שונות לגמרי, זו לצד זו: הגישה הקלאסית מניחה שהאחוז האמיתי הוא מספר קבוע אחד שפשוט לא ידוע, ומנסה לאמוד אותו; הגישה הבייסאנית מתייחסת לאותו אחוז עצמו כאל משתנה מקרי עם התפלגות אמון, ומעדכנת אותה ככל שרואים יותר נתונים. אני מריצה את שתי הגישות על אותו דאטה בדיוק, ומשווה תוצאות בכל שלב.

לצד ספריות העבודה הרגילות עם מספרים, טבלאות וגרפים, נטענים כאן גם הכלים הקלאסיים וגם הכלים הבייסאניים.

הדאטה עצמו

לפני שממשיכים, בואו נדבר קצת על הדאטה עצמו ומה הוא בכלל מייצג. המאגר שבחרתי, star98, הוא אוסף נתונים אמיתי על 303 מחוזות חינוך בקליפורניה, מובנה בתוך חבילת statsmodels בפיתוח ונוצר במקור כדי ללמד רגרסיה בינומית, בדיוק מה שעושים כאן. בכל מחוז, כל תלמידי כיתה מסוימת ניגשו למבחן קריאה סטנדרטי ארצי, ואנחנו יודעים כמה תלמידים ניקדו מעל החציון הארצי, וכמה ניקדו מתחתיו או בדיוק עליו. כלומר בשביל כל מחוז יש לנו בעצם תוצאה בינארית, עבר את החציון או לא, עבור כל אחד מהתלמידים שבו.

שתי עמודות נוספות מעל הנתונים הגולמיים: גודל המחוז הכולל, שהוא פשוט סכום התלמידים שעברו ושלא עברו, ואחוז ההצלחה, שהוא היחס ביניהם. שתי ההיסטוגרמות זו לצד זו מראות שני דברים שונים: בגרף השמאלי ציר ה-X הוא אחוז ההצלחה וציר ה-Y הוא כמה מחוזות נמצאים בכל טווח אחוזים, ורואים שרוב המחוזות מרוכזים סביב ארבעים עד חמישים אחוז הצלחה בערך. בגרף הימני ציר ה-X הוא הגודל של המחוז בסקאלה לוגריתמית, כי הטווח כל כך רחב, ורואים פיזור עצום: משלושים ושלושה תלמידים במחוז הכי קטן ועד כמעט שלושים ותשעה אלף במחוז הכי גדול. השוני העצום הזה בגודל הוא מרכיב מרכזי שישחק תפקיד בהמשך, כשנגיע לתופעה שנקראת כיווץ.

מחוז בודד: התשובה הקלאסית

מתחילים במחוז בודד אחד, ובודקים אותו קודם כל דרך הגישה הקלאסית. שתי השאלות שמנחות את כל הקטע הזה פשוטות: מה אחוז ההצלחה האמיתי של המחוז הזה, שנשמך אותו p כמו שנכתוב בקוד בהמשך, ואיך אני בכלל אומדת אותו ועד כמה אני יכולה לבטוח באומדן. כדי לשחזר את הדוגמה הקלאסית של מטבע בודד, הדוגמה כאן מתמקדת במחוז אחד, זה שגודלו הכי קרוב לחציון, כדי שהמספרים יהיו נוחים לקריאה. הווקטור המדויק של אפסים ואחדים לכל תלמיד באותו מחוז נבנה מחדש כאן, ואלה בדיוק הנתונים האמיתיים שנרשמו, לא סימולציה.

הממוצע הפשוט של הנתונים האלה, שבקוד נקרא $\hat{p}$ ויוצא סביב 0.62, הוא אומדן הנקודה הקלאסי של p , כלומר הניחוש הכי טוב שיש לנו כרגע לאחוז ההצלחה האמיתי של המחוז, ועליו בונים מיד את רווחי הסמך הבאים.

יש כאן שלושה סוגי רווחי סמך קלאסיים של 95 אחוז, כל אחד בשמו. הראשון, רווח וולד (Wald), הנוסחה הכי סטנדרטית מהספר, מבוסס על כך שלפי משפט הגבול המרכזי, האומדן מתפלג בקירוב נורמלי סביב הערך האמיתי, כך שרוב שטח ההתפלגות הנורמלית נמצא בטווח צר סביב הממוצע. השני, רווח בוטסטרפ, מבוסס על עיקרון שונה לגמרי: יש לי כמה מאות תוצאות אמיתיות, ואני מדמה מדגמים חדשים על ידי דגימה מחדש בהחזרה מתוך אותם הערכים בדיוק, כלומר בוחרים באקראי אותו מספר פעמים, כשכל תצפית מקורית יכולה להיבחר שוב או לא להיבחר כלל, מחשבים את האומדן על המדגם המדומה, וחוזרים על זה אלפי פעמים. הפיזור של כל האומדנים האלה מדמה את הפיזור שהיינו רואים אם באמת חזרנו ואספנו מדגמים חדשים, וממנו לוקחים את התחום שמכיל 95 אחוז מהערכים. השלישי, רווח וילסון (Wilson), נוסחה פחות מוכרת אבל יותר מדויקת במדגמים קטנים. שלושת הרווחים יוצאים כאן כמעט זהים.

כדי להבין את ההבדל הפילוסופי בין שתי הגישות, שאלתי את הצ'אט:

Chat, discuss the differences between Bayesian and frequentist statistics, using this example of estimating a school's pass rate.

והוא ענה שהגישה הקלאסית מתייחסת לאחוז ההצלחה כמספר קבוע לא ידוע, ורווח הסמך הוא בעצם אמירה על התהליך, לא על הערך עצמו: אם היינו חוזרות על הדגימה הרבה פעמים, ב-95 אחוז מהפעמים הרווח היה מכיל את הערך האמיתי. הגישה הבייסאנית, לעומת זאת, הופכת את הערך עצמו למשתנה מקרי, ואז אפשר להגיד ישירות שיש 95 אחוז סיכוי שהוא בטווח הזה. זהו הבדל אמיתי בין אמירה על תהליך לאמירה ישירה על הפרמטר.

רווח וולד, למרות שהוא הכי מוכר, נשען על קירוב שנחלש במדגמים קטנים או באחוזים קיצוניים. כדי לבדוק אם אפשר לסמוך עליו במקרה כזה, בניתי סימולציה: מחוז קטן היפותטי עם ארבעים תלמידים ואחוז הצלחה נמוך, ואלפי הדמיות חוזרות, שבכל אחת מהן נבנה רווח סמך חדש ונבדק אם הוא מכיל את הערך האמיתי. וולד כיסה את האמת רק ב-86.2 אחוז מהפעמים, במקום 95 אחוז שהוא מבטיח. וילסון, נוסחה פחות מוכרת, הגיע ל-94.1 אחוז, קרוב מאוד להבטחה. (בוטסטרפ לא נכלל בסימולציה, כי הרצה שלו אלפי פעמים יקרה מדי חישובית.)

התשובה הבייסאנית: פריור בטא

עכשיו לאותה שאלה בדיוק, אבל דרך הגישה הבייסאנית. לפני שראיתי נתונים, אני לא יודעת כלום על אחוז ההצלחה מלבד שהוא בין אפס לאחת, וזה בדיוק פריור בטא עם שני הפרמטרים שווים לאחת, שהוא בעצם התפלגות אחידה. בגרף שמראה אותו, ציר ה- X הוא בין אפס לאחת, ציר ה- Y הוא צפיפות ההסתברות, ויוצא קו ישר אופקי, כי כל ערך אפשרי סביר באותה מידה מראש.

שני השלבים הבאים של חוק בייס כתובים כאן גם כנוסחאות, לא רק במילים. אם אחוז ההצלחה שווה ל- x , כל תלמיד הוא הטלת מטבע ברנולי עם אותה הסתברות x , ותלמידים בלתי-תלויים, אז הלייקליהוד, ההסתברות לראות בדיוק את הנתונים שראינו בהינתן ש- x הוא הערך האמיתי, הוא בדיוק מכפלת כל התוצאות הבודדות, וזה שווה להתפלגות בינומית: $LIKELIHOOD$ של הנתונים בהינתן p שווה למכפלה

של כל הברנולי, ששווה ל-Binomial(n, x). ולפי חוק בייס עצמו, הפוסטריורי, ההסתברות של p בהינתן הנתונים, פרופורציונלי למכפלת הלייקליהוד בפריור: $\text{POSTERIOR}(p)$ פרופורציונלי ל-LIKELIHOOD כפול PRIOR . שתי הנוסחאות האלה הן בדיוק מה שמאפשר לעבור מהקו השטוח של הפריור לעקומה הצרה של הפוסטריורי שנראה עוד רגע.

שאלתי את הצ'אט למה דווקא התפלגות בטא היא הבחירה הטבעית כאן:

Chat, why is the Beta distribution the natural conjugate prior for a Binomial likelihood?

והוא ענה שזה נובע מכך שהצורה האלגברית של הלייקליהוד הבינומי זהה לצורה של צפיפות בטא, ולכן הכפל ביניהן רק מוסיף מעריכים. זה בדיוק מה שנקרא פריור צמוד: אחרי שרואים כמה הצלחות מתוך כמה ניסיונות, הפוסטריורי הוא שוב בטא, רק עם פרמטרים מעודכנים בחיבור פשוט, בלי שום אינטגרציה נומרית.

הגרף כאן מראה שתי עקומות: הפריור השטוח, ולידו הפוסטריורי אחרי שראינו את הנתונים. חשוב להבין מה שתי העקומות האלה בעצם אומרות, לא רק איך הן נראות. הקו השטוח של הפריור אומר: לפני שראיתי אפילו תלמיד אחד מהמחוז הזה, כל ערך אפשרי נראה לי סביר באותה מידה בדיוק, אין לי שום מושג אם המחוז מצליח או נכשל. העקומה הצרה והממוקדת של הפוסטריורי אומרת: אחרי שראיתי את הנתונים, אני עכשיו כמעט בטוחה שאחוז ההצלחה האמיתי של המחוז נמצא באזור צר סביב 0.62, וערכים קיצוניים הפכו בלתי סבירים כמעט לגמרי. זו בדיוק המשמעות של עדכון אמונות לפי נתונים: התמונה עברה מבורות מוחלטת לביטחון ממוקד, וזה בדיוק מה שהגרף מראה חזותית.

עכשיו ב-PyMC

כדי לממש את המודל הבייסאני הזה בפועל, עוברים לכתוב אותו בקוד, בעזרת הספרייה `pymc`. כאן עשיתי משהו קצת שונה ממה שהיה מתבקש להעתיק ישירות: במקום לייצג כל תלמיד כשורה נפרדת, אני משתמשת בפונקציה שמייצגת ישירות את הספירה המצטברת של הצלחות מתוך סך הניסיונות. מה השורה הזאת בעצם עושה בפועל? היא מגדירה בתוך המודל משתנה חדש, ואומרת עליו שני דברים בבת אחת: ראשית, שהוא מתפלג בינומית עם מספר הניסיונות של המחוז והסתברות ההצלחה שהגדרנו שורה קודם עם הפריור. שנית, שהוא נצפה בערך ספציפי, כלומר לא צריך לדגום אותו בכלל, כי אנחנו כבר יודעים בוודאות מה הוא שווה, זה מה שבאמת קרה במחוז הזה. השילוב הזה הוא בדיוק מה שמחבר את הדאטה למודל: כך המערכת מחשבת, לכל ערך היפותטי של אחוז ההצלחה, כמה סביר היה לראות בדיוק את התוצאה שראינו, אילו הערך היה שווה לו, וזה בדיוק הלייקליהוד שנכנס לחוק בייס. בלי השורה הזאת, למודל לא הייתה שום דרך לפגוש את הנתונים האמיתיים בכלל.

מבחינה מתמטית, קידוד הנתונים כספירה מצטברת אמור לתת פוסטריורי זהה לחלוטין לקידוד של כל תלמיד בנפרד, בזכות עיקרון שנקרא מספיקות סטטיסטית, אבל לא הסתפקתי בטענה הזו, ושאלתי את הצ'אט אם אפשר להראות את זה ולא רק להצהיר:

Chat, is the `pm.Binomial` encoding really identical to a per-student `pm.Bernoulli` array? Show me, don't just assert it.

והוא אישר את זה, אבל הציע לא להסתפק בטענה תיאורטית, אלא להראות את זה בפועל: כדי לדעת כמה שאפשר על אחוז ההצלחה, לא צריך לדעת את הסדר המדויק שבו הצליחו ונכשלו התלמידים, צריך לדעת רק כמה בסך הכל עברו, כי הסכום הזה הוא תמצית שמכילה בתוכה את כל המידע. הדרך להראות את זה בפועל היא להריץ את שני הקידודים על אותם נתונים בדיוק ולהשוות את הפוסטריורים המתקבלים במספרים.

עשיתי בדיוק את זה: הרצתי גם את הגרסה שמייצגת כל תלמיד בנפרד, על אותו הווקטור המקורי, והשוויתי את שני הפוסטריורים במספרים: הממוצע הפוסטריורי יוצא זהה בשני המקרים עד כדי הבדל זניח ברעש הדגימה, וכך גם סטיית התקן. טענת המספיקות לא נשארה טענה תיאורטית, נבדקה ואומתה. לפני שדוגמים בכלל, יש כאן דיאגרמה גרפית של מבנה המודל עצמו: עיגול פתוח לפרמטר הנסתר, עם חץ שיוצא ממנו לתוך עיגול מוצל שמייצג את מה שנצפה בפועל.

כדאי לעצור כאן רגע ולהסביר מה באמת קורה בדגימה, כי זה הלב של כל הגישה הבייסאנית המודרנית. הבעיה: הפוסטריורי כאן פשוט, יש לו נוסחה סגורה כמו שראינו למעלה, אבל ברוב המודלים המעניינים, ובטח בהמשך המחברת, אין נוסחה סגורה כזאת, כי האינטגרל שצריך כדי לנרמל אותו פשוט לא פתיר באופן אנליטי. הפתרון: אם אי אפשר לחשב את הצורה המדויקת של הפוסטריורי, אפשר במקום זה לדגום ממנו, לייצר הרבה מאוד ערכים אקראיים כך שההתפלגות שלהם תדמה ככל האפשר לצורה האמיתית, גם בלי לדעת את הנוסחה במפורש. זה בדיוק מה שדגימת שרשראות מרקוב מונטה קרלו עושה: בונים שרשרת של ניחושים עוקבים לערך הפרמטר, כל ניחוש חדש נגזר מהניחוש הקודם, בצורה שמעוצבת מתמטית כך שאחרי מספיק צעדים, ההתפלגות של הניחושים מתכנסת בדיוק לפוסטריורי האמיתי. האלגוריתם הספציפי שהספרייה משתמשת בו לא מנחש כיוונים אקראיים גרידא, אלא משתמש בשיפוע של הפוסטריורי כדי לדעת לאיזה כיוון כדאי לזוז, ממש כמו כדור שמתגלגל על פני התוואי, וכך חוקר את המרחב הרבה יותר מהר מניחוש טיפשי.

ארבע שרשראות רצות כאן במקביל, בלתי תלויות, כל אחת מנקודת התחלה אחרת, ואם כולן מתכנסות לאותה התפלגות זו עדות חזקה שאנחנו רואים את הפוסטריורי האמיתי ולא תקלה מקומית. לכל שרשרת יש שלב חימום שנזרק ולא נספר, ורק אחריו מתחילים לספור את הדגימות שנשמרות בפועל.

גרף מסלול הדגימה כאן: ציר ה-X הוא מספר הדגימה, ציר ה-Y הוא הערך שנדגם, וארבעה קווי צבע, אחד לכל שרשרת, שצריכים להיראות כמו רעש חסר מבנה שקופץ סביב אותו אזור ולחפוף כמעט לגמרי, לא כמו מגמה או תקיעות במקום אחד. הערת גרסה: בגרסת arviz הישנה הפונקציה הזאת הציגה גם פאנל צפיפות בנוסף למסלול; בגרסה המותקנת כאן היא מציגה רק את המסלול עצמו, ואת הצפיפות רואים בנפרד דרך `az.plot_dist` שכבר השתמשנו בו. כלומר הפלט שרואים כאן הוא בדיוק ארבע שרשראות של דגימות מהפוסטריורי, אחרי שלב החימום שכבר נזרק. שווה גם לחשוב רגע מה היה משתנה אילו השתמשתי במערך המלא של כל תלמיד בנפרד במקום בספירה המצטברת: הפוסטריורי המתקבל היה זהה לגמרי בזכות המספיקות שכבר בדקנו, אבל כל צעד של האלגוריתם היה צריך לחשב מאות הסתברויות בנפרד במקום הסתברות בינומית אחת, כך שזה היה הרבה יותר איטי, בלי לשנות את התשובה בכלל.

אחרי שיש לנו גם דגימות מהפוסטריורי המלא, אפשר סוף סוף להשוות ישירות בין רווח האמון הבייסאני לשלושת רווחי הסמך הקלאסיים. הגרף הזה מראה את הפוסטריורי דרך עקומת צפיפות, קו לאומדן הנקודה, ותחום מוצלל לרווח האמון של 95 אחוז. הערת גרסה: הקוד המקורי מציג את זה בפונקציה שכבר לא קיימת בגרסה הנוכחית של הספרייה, ומוזגה לתוך גרסה כללית יותר שנותנת בדיוק אותה תמונה.

לצד הגרף יש גם טבלת סיכום סטנדרטית של arviz, עם כמה עמודות אבחון שיחזרו לאורך כל המחברת וכדאי להסביר פעם אחת כאן: `ess_bulk` ו-`ess_tail` הם גודל המדגם האפקטיבי, כלומר כמה דגימות בלתי-תלויות שוות-ערך יש לנו בפועל ולא כמה דגימות יש על הנייר; ו-`r_hat` הוא מדד ההתכנסות של גלמן-רובין, שמשווה את השונות בין השרשראות השונות לשונות בתוך כל שרשרת בנפרד. ערך קרוב מאוד לאחת, כמו שרואים כאן, אומר ששרשראות שהתחילו מנקודות התחלה שונות התכנסו לאותה התפלגות בדיוק; ערך גבוה משמעותית מאחת הוא אזהרה שהדגימה לא באמת התכנסה ואי אפשר לסמוך על התוצאה.

עכשיו הרגע המרכזי: כל ארבעת הרווחים, שלושת הקלאסיים ורווח האמון הבייסאני, מופיעים אחד מתחת לשני באותו גרף, כל אחד כקו אופקי באורך הרווח שלו. עבור המחוז הזה, עם מדגם בגודל בינוני ופריור שטוח, כל הארבעה כמעט זהים לגמרי, בדיוק כמו שהתאוריה הא-סימפטוטית מנבאת. אבל, כפי שראינו קודם, זה לא תמיד המצב במחוזות קטנים.

מבחן השערות: פקטור בייס מול מבחן קלאסי

עד כה השאלה הייתה כמה גבוה אחוז ההצלחה. עכשיו שאלה מסוג אחר: האם המחוז שלנו שונה מהממוצע הארצי, שיוצא סביב 44 אחוז. בגישה הקלאסית, מבחן בינומי מדויק, שנותן ערך מובהקות זעיר. שאלתי את הצ'אט מה הגישה הבייסאנית המקבילה:

Chat, what's the Bayes factor and how does it compare to a classical significance test here? What are H_0 and H_1 , and how does arviz compute it?

והוא ענה שפקטור בייס מחושב דרך יחס בין שתי צפיפויות, בשיטה שנקראת יחס Savage-Dickey: משווים את צפיפות הפוסטריורי בערך הייחוס לצפיפות הפריור באותה נקודה בדיוק. H_0 כאן הוא שאחוז ההצלחה של המחוז שווה לממוצע הארצי, ו- H_1 שהוא שונה ממנו.

בגרף הזה: שתי עקומות צפיפות על אותו ציר X של אחוז הצלחה, אחת לפריור ואחת לפוסטריורי, וקו אנכי מסמן את ערך הייחוס, הממוצע הארצי. פקטור בייס הוא בדיוק היחס בין גובה שתי העקומות באותה נקודה על הקו האנכי, וזה בדיוק הערך שהכותרת של הגרף מדפיסה.

וכאן קרה משהו אמיתי שכדאי לספר עליו: כשהרצתי את התא, קפצה אזהרה מהספרייה שאומרת שערך הייחוס נמצא מחוץ לטווח הפוסטריורי, ושזה עלול להגזים בעדות בעד ההשערה. זו בדיוק המלכודת שהקורס שואל עליה, וקיבלתי אותה בפועל, לא רק בתיאוריה. ההסבר: הפוסטריורי של המחוז הזה נמצא הרחק מהממוצע הארצי, וכשערך הייחוס רחוק מהתחום שיש בו בכלל דגימות, אומדן הצפיפות צריך לנחש את הערך שם, וזה לא אמין. אני מציינת בפירוש שהמספר של פקטור בייס כאן פחות אמין, אבל הכיוון שלו, שהמחוז שונה משמעותית מהממוצע הארצי, נתמך גם על ידי ערך המובהקות הזעיר של המבחן הקלאסי.

שאלתי את הצ'אט גם איך לפרש את הגודל של פקטור בייס, ולמה הוא ומבחן קלאסי יכולים לסתור זה את זה:

Chat, how should I interpret the Bayes factor value above, and why might it disagree with the p-value?

והוא ענה שיש סולם מקובל שממייין אותו מ"כמעט לא משמעותי", כשהמספר בין 1 ל-3, ועד "מכריע", כשהמספר מעל 100. בנוסף הוא הסביר שזה יכול לסתור את ערך המובהקות, כיוון שעם מדגם גדול ערך המובהקות יכול לצאת קטן גם על הבדל זניח, בעוד פקטור בייס נשאר זהיר יותר. המצב הזה נקרא הפרדוקס של לינדלי, והוא הבדל מבני אמיתי בין שתי הגישות, לא טעות.

אומדני בייס: ממוצע וחציון

יש לי כבר את הפוסטריורי המלא של המחוז, אבל לפעמים רוצים לדווח מספר יחיד במקום התפלגות שלמה. שאלתי את הצ'אט מה ההבדל בין אומדן נקודה רגיל לאומדן בייס, ואיזו פונקציית אובדן עומדת מאחורי כל אחד:

Chat, what's the difference between a point estimate and a Bayes estimator, and which loss function corresponds to the posterior mean vs. the posterior median?

והוא ענה שאומדן בייס ממזער אובדן צפוי לפי פונקציית אובדן שבחרים: הממוצע הפוסטריורי ממזער שגיאה ריבועית, והחציון ממזער שגיאה מוחלטת.

בגרף הזה: ציר ה-X הוא ערך מועמד לאומדן, בין אפס לאחת, וציר ה-Y הוא האובדן הצפוי אילו בחרנו בערך הזה: שתי עקומות, אחת ל-L2 ואחת ל-L1, ונקודה שמסמנת את המינימום של כל אחת. המינימומים האלה חופפים בדיוק לממוצע ולחציון של הפוסטריורי שכבר חישבתי קודם, בדיוק כמו שהתיאוריה מבטיחה.

התפלגות חיזוי פוסטריורית

מעבר לאמידת הפרמטר עצמו, אפשר גם לשאול מה צפוי לקרות בעתיד. שאלתי את הצ'אט מה בכלל ההבדל בין הפוסטריורי לבין התפלגות חיזוי פוסטריורית:

Chat, what's the difference between the posterior and the posterior predictive distribution, using this district as the example?

והוא הבהיר שהפוסטריורי מתאר את האמון שלנו על הפרמטר עצמו, ואילו התפלגות החיזוי מתארת תחזית לתצפית חדשה, כמו כמה תלמידים היו עוברים אילו בדקנו עוד קבוצה מאותו מחוז. התפלגות החיזוי כוללת גם את אי-הוודאות על הפרמטר וגם את השונות האקראית הרגילה של דגימה חדשה.

ההיסטוגרמה הזאת: ציר ה-X הוא מספר תלמידים שהיו עוברים את הרף בהדמיה אחת, וציר ה-Y הוא כמה מבין אלפי ההדמיות נתנו כל מספר כזה. קו אנכי מסמן את המספר שבאמת נצפה בפועל באותו מחוז, והוא נופל בדיוק בתוך תחום הצפיפות הגבוהה של ההיסטוגרמה, כלומר המודל היה "מופתע" רק מעט מהתוצאה האמיתית, סימן בריא.

עכשיו החלק המרכזי השני, ועכשיו השאלות קצת שונות: האם המחוזות דומים בממוצע? האם כל מחוז שונה מהאחרים? האם מחוז ספציפי שונה ממחוז אחר? והאם כולם בכלל מגיעים מאוכלוסייה משותפת אחת? כל 303 המחוזות עברו את אותו מבחן ארצי, אז יש הצדקה סבירה להתייחס אליהם כבאים מאותה יציקה, בדיוק כמו הרעיון של כמה מטבעות מאותו בית מטבעות. בוחרת עשרה מחוזות שפרוסים בכוונה על פני כל טווח הגדלים, כי בדיוק השוני הזה הופך את תופעת הכיווץ לגלויה. בטבלה כאן רואים את ספירת ההצלחות, ספירת הכישלונות, הגודל הכולל, ואחוז ההצלחה של כל אחד מהם.

במודל העצמאי, לכל מחוז יש אחוז הצלחה משלו, לגמרי בלתי תלוי באחרים. שוב יש כאן דיאגרמת מודל: עיגול פתוח אחד לפרמטר ההצלחה, אבל הפעם הוא מסומן כמערך של עשרה ערכים ולא ערך בודד, אחד לכל מחוז בתת-הקבוצה, וכולם מזינים חץ לתוך התצפיות. בטבלת הסיכום, המחוז הקטן ביותר יוצא עם רווח אמון רחב יחסית, כי יש לו מעט מאוד תלמידים, בעוד מחוז גדול יותר יוצא עם רווח הרבה יותר צר.

בטבלה יש כבר את ערך ה- $\hat{r}$ שכבר הסברתי קודם, אבל עם עשרה פרמטרים כדאי גם לראות את זה חזותית ולא רק להסתמך על המספר בטבלה. יש כאן גרף מסלול נפרד לכל אחד מעשרת המחוזות: בכל פאנל ציר ה-X הוא מספר הדגימה וציר ה-Y הוא אחוז ההצלחה שנדגם, וארבעה צבעים לארבע השרשראות. בכל אחד מעשרת הפאנלים ארבעת הצבעים חופפים לגמרי לרעש חסר מבנה, בדיוק כמו במחוז הבודד שראינו קודם, כלומר ההתכנסות נראית תקינה לא רק במספר אלא גם חזותית, על כל אחד מהפרמטרים בנפרד.

השוואת שני מחוזות ספציפיים: מבחני קונטינגנטיות מול הפרש פוסטריורי

עד כה כל השוואה במחברת הייתה על פרופורציה בודדת אל מול ערך ייחוס קבוע. שאלה נפוצה לא פחות היא האם שני מחוזות ספציפיים שונים ממש זה מזה, וזו בעיה קלאסית של טבלת קונטינגנטיות: מחוז כפול עבר-או-לא-עבר. בוחרת את שני המחוזות עם ההבדל הכי בולט באחוז ההצלחה שלהם, אחד חזק מאוד ואחד חלש יחסית. לפני שמריצה את המבחנים, שאלתי את הצ'אט על עקרון מבחן פישר המדויק:

Chat, what's the test statistic in Fisher's exact test, and why are its "marginals" fixed?

והוא הסביר שמבחן פישר המדויק מתנה על כך ששני סוגי הסכומים בטבלה, סך התלמידים בכל מחוז וסך העוברים הכולל, קבועים, ומחשב את ההסתברות המדויקת, לפי התפלגות היפרגאומטרית, שתקבל טבלה קיצונית לפחות כמו זו שנצפתה. מכאן השם "מדויק", כי אין כאן שום קירוב למדגם גדול. קיבוע הסכום של כל מחוז טבעי כאן, כי זה פשוט מספר התלמידים בו ולא משהו אקראי. קיבוע הסכום הכולל נוח יותר מבחינה מתמטית מאשר הנחה מהותית, אבל זו הפרקטיקה הסטנדרטית, והמבחן מתלכד היטב עם מבחן חי-בריבוע כל עוד התאים הצפויים בטבלה לא זעירים.

הרצתי את שני המבחנים, מבחן פישר המדויק ומבחן חי-בריבוע, על הטבלה של שני המחוזות האלה, וקיבלתי בשניהם ערכי מובהקות זעירים ביותר, מה שלא מפתיע לאור פער של קרוב לחמישים נקודות אחוז בין שני מחוזות עם אלפי תלמידים משותפים. שאלתי גם מה זה אומדן יחס הסיכויים, ומה ההנחות של מבחן חי-בריבוע:

Chat, what's an odds ratio, and what are the assumptions of the chi-squared test here?

והוא הסביר שיחס הסיכויים משווה את סיכויי ההצלחה במחוז אחד לסיכויי ההצלחה במחוז השני, וערך רחוק מאחת אומר ששני המחוזות שונים משמעותית באחוז ההצלחה שלהם. השערת האפס של שני המבחנים היא בדיוק שיחס הסיכויים שווה אחת, כלומר ששני המחוזות חולקים את אותו אחוז הצלחה אמיתי. מבחן חי-בריבוע דורש בנוסף שהתא הצפוי בכל משבצת בטבלה יהיה גדול דיו, כלל אצבע נפוץ הוא לפחות חמישה, ועם שני מחוזות בגודל כזה ההנחה הזאת מתקיימת בנוחות, ולכן שני המבחנים כאן מתלכדים כל כך.

עכשיו הצד הבייסאני של אותה שאלה: במקום מבחן בודד עם ערך מובהקות אחד, יש לנו כבר פוסטריורי מלא לשני המחוזות ממודל העצמאי, כך שאפשר להסתכל ישירות על ההפרש בין שני הפוסטריורים. רווח האמון של 95 אחוז על ההפרש יוצא רחוק מאוד מאפס בשני הכיוונים, בהתאמה מלאה לדחייה הנחרצת של שני המבחנים הקלאסיים. אבל השורה האחרונה שם היא סוג שונה לגמרי של אמירה: ההסתברות הפוסטריורית שהמחוז החזק באמת עולה על החלש יוצאת קרוב לוודאות מוחלטת, וזו אמירת הסתברות ישירה על השאלה שבאמת מעניינת אותנו, שמחושבת מהדגימות שכבר היו לנו, בלי צורך במבחן נפרד. ערך מובהקות, לעומת זאת, מבחינה מבנית לא יכול להתפרש כהסתברות שהשערת האפס נכונה: הוא ההסתברות לנתונים קיצוניים כאלה בהינתן שהשערת האפס נכונה, שאלה שונה ומסורבלת יותר מזו שבדרך כלל רוצים לענות עליה בפועל.

מודל היררכי

המודל העצמאי לא מנצל בכלל את זה שכל המחוזות שייכים לאותה מדינה ואותו מבחן ארצי. המודל ההיררכי הבא מתקן בדיוק את זה: מוסיפים שכבה משותפת, פריור-על על הממוצע האוכלוסייתי, ופרמטר נוסף שמבטא כמה ריכוז יש סביב הממוצע הזה, כמו גודל מדגם דמיוני. כל מחוז מקבל אחוז הצלחה משלו, אבל הוא נשלף מהתפלגות בטא שהפרמטרים שלה עצמם משותפים לכולם, כך שמידע זולג בין המחוזות. שוב יש כאן דיאגרמה, וההבדל הוויזואלי מהמודל העצמאי בולט מיד: יש שני עיגולים נוספים שמזינים חץ לתוך הפרמטר, במקום שהוא יקבל מספרים קבועים כהורים שלו.

שאלתי את הצ'אט למה משתמשים בפרמטריזציה הזאת, ממוצע אוכלוסייתי וריכוז, במקום שני הפרמטרים הרגילים של בטא:

Chat, why is the $\text{Beta}(\mu, \nu)$ parametrization used here instead of $\text{Beta}(\alpha, \beta)$, and what does ν mean?

והוא הסביר שהצורה הזאת ניתנת לפירוש ישיר: מיו הוא הממוצע, ν הוא בערך "גודל מדגם דמיוני" שקובע כמה צר הפריור סביב הממוצע. זה מאפשר לשים פריור-על ישירות על הממוצע האוכלוסייתי ועל מידת השונות המותרת בין מחוזות, וזה בדיוק המנגנון שמאפשר זרימת מידע בין המחוזות בזמן הדגימה.

בפועל, הממוצע האוכלוסייתי המשותף יוצא סביב 0.38, ופרמטר הריכוז יוצא סביב 9.6. מה זה אומר בפועל? ש-38 אחוז הוא בערך אחוז ההצלחה הטיפוסי שממנו כל המחוזות בקבוצה סוטים, ושהריכוז הקטן יחסית, בהשוואה למחוזות עם מאות או אלפי תלמידים, אומר שהמודל לא בטוח שכל המחוזות דומים מאוד זה לזה: הוא מרשה למחוזות לסטות באופן משמעותי מהממוצע המשותף, לא כופה עליהם להיות כמעט זהים. פרמטר ריכוז גדול הרבה יותר היה אומר שכל המחוזות כמעט זהים וכל סטייה היא רעש בלבד, וזה לא המצב כאן.

גם כאן, עם עשרה פרמטרים במודל ההיררכי, כדאי לבדוק התכנסות חזותית ולא רק להסתפק בטבלה. הפעם הכלי הוא אחר, שמתאים יותר להציג הרבה פרמטרים יחד: גרף יער, שבו ציר ה-Y הוא עשרת המחוזות וציר ה-X הוא אחוז ההצלחה המוערך; בכל שורה יש ארבעה קווי שגיאה חופפים, אחד לכל שרשרת, כל אחד עם נקודה שמסמנת את האומדן שלו ורווח סביבו. ככל שארבעת הקווים בכל שורה חופפים חזק יותר זה על זה, כך יש יותר הסכמה בין השרשראות, שוב בדיוק סימן חזותי להתכנסות. מיו ונו לא מופיעים בגרף הזה בכוונה: הסקאלה שלהם שונה לגמרי מזו של אחוזי ההצלחה, וגרף אחד עם שני הסוגים ביחד היה הופך את הרווחים של המחוזות לבלתי נראים.

כיווץ

הגענו לתופעה שכבר הזכרתי בהתחלה, כשדיברנו על השוני בגודל בין המחוזות: כיווץ. שאלתי את הצ'אט מה זה בעצם, ואיך המודל ההיררכי יוצר אותו:

Chat, what is shrinkage, and how does the hierarchical model produce it here?

והוא הסביר שבמודל העצמאי, לכל מחוז יש רק את הנתונים שלו, ומחוז עם מעט תלמידים מקבל פוסטריורי רחב ולא בטוח. במודל ההיררכי, כל מחוז גם נמשך לכיוון הממוצע המשותף, וחוזק המשיכה תלוי כמה נתונים יש למחוז הזה עצמו: מחוזות קטנים נמשכים חזק, מחוזות גדולים כמעט ולא זזים, כי הנתונים שלהם כבר גוברים על ההשפעה המשותפת. זה בדיוק המנגנון של אומדן גיימס-שטיין, מנגנון סטטיסטי קלאסי ומפורסם, רק שכאן הוא יוצא באופן טבעי ממבנה המודל ההיררכי, בלי שהיה צריך להמציא אותו בנפרד.

השוואת מודלים: מ-WAIC ל-LOO

עכשיו יש לי שני מודלים בייסאניים לאותו דאטה, העצמאי וההיררכי, ואיך בכלל בוחרים ביניהם? הם לא מקוננים, כלומר אי אפשר לצמצם את ההיררכי לעצמאי פשוט על ידי איפוס פרמטר, כך שמבחן יחס-נראות קלאסי לא רלוונטי כאן, וגם פקטור בייס בין שני מודלים כאלה דורש נראות שולית שקשה מאוד לחשב בפועל. הכלי הסטנדרטי במקרה כזה הוא מדד מבוסס נראות-חיזוי-מקומית.

נקודה שחשוב לספר עליה בקול, כי היא בדיוק דוגמה לגרסה של ספרייה שהשתנתה: כתבתי במקור את הקוד בדיוק כמו שהנראות הקורס מציגות, עם המדד הישן שנקרא WAIC, וקיבלתי שגיאה שאין פרמטר כזה. מסתבר שהגרסה העדכנית של הספרייה הסירה לגמרי את האפשרות לבחור במדד הישן, ועברה כברירת מחדל למדד חדש שנקרא LOO, מבוסס אימות בהוצאה-אחת-בכל-פעם. הרעיון: הדרך הנכונה לבדוק כמה טוב מודל היא להוציא כל תצפית בתורה, לאמן מחדש בלעדיה, ולבדוק כמה טוב המודל חוזה את מה שהוצא, אבל לאמן מחדש עשר פעמים, ובוודאי שלוש פעמים, עם דגימת שרשראות מרקוב, יקר מדי בפועל. הפתרון החכם הוא לא לאמן מחדש בפועל, אלא לשקלל מחדש את הדגימות שכבר יש לנו, כך שהן מדמות איך היה נראה הפוסטריורי בלי התצפית הזאת. היתרון על המדד הישן: יש למדד החדש בדיקת תקינות מובנית שמזהה בדיוק מתי השקלול הזה לא אמין, ולמדד הישן אין דבר כזה.

בטבלת ההשוואה: המודל ההיררכי מדורג ראשון, ההפרש שלו מוגדר כאפס כבסיס להשוואה, והמודל העצמאי מדורג שני, גרוע יותר ביחידת ניקוד אחת בערך, אבל עם שגיאה תקנית של ההפרש שגדולה יחסית להפרש עצמו, כלומר ההבדל הזה קטן ביחס לרעש שלו, לא הבדל דרמטי. עמודת המשקל נותנת משקל מלא להיררכי ואפס לעצמאי, אם רוצים לשלב תחזיות משני המודלים.

אותה טבלה מוצגת גם כגרף. ציר X הוא הפרש ה-ELPD, מדד נראות-החיזוי של כל מודל על תצפיות שהוצאו ממנו, כשערך גבוה יותר אומר חיזוי טוב יותר; כל מודל מקבל שורה משלו על ציר Y. המודל המדורג ראשון, ההיררכי, יושב בדיוק על קו מקווקו אנכי באפס: הוא קו הייחוס שכל שאר המודלים נמדדים ביחסיו. המודל העצמאי מסומן בנקודה על ההפרש שלו, סביב מינוס אחת, עם קו אופקי סביבה שהוא טווח השגיאה התקנית של אותו הפרש, וכיוון שהקו הזה חוצה את קו האפס, ההבדל בין שני המודלים קטן ביחס לרעש שלו, בדיוק כמו שכבר ראינו במספרים בטבלה. שווה לציין גם: הכותרת "higher is better" שמופיעה על הגרף היא לא תוספת שלי, היא מגיעה מובנית מתוך הפונקציה עצמה בגרסת arviz המותקנת כאן, עוד סימן לכך שהגרסה החדשה של הספרייה לא רק שינתה את המדד מ-WAIC ל-LOO, אלא גם שכתבה מחדש את כל מנגנון הציור של הפונקציה הזאת.

וכשהרצתי את ההשוואה, אכן קפצה אזהרה שערך אבחוני מסוים גבוה מדי עבור כמה תצפיות. וכאן קרה דבר מעניין שחייבת לספר עליו: הניחוש הראשוני שלי היה שזה בטח המחוז הענק, כמעט שלוש תשעה אלף תלמידים, שגורם לבעיה. בדקתי את זה בפועל במקום להסתפק בניחוש, והתברר שהניחוש שגוי לחלוטין: דווקא המחוז הענק קיבל את אחד הציונים הכי טובים, בעוד שרוב שאר המחוזות בקבוצה סומנו כבעייתיים. ההסבר האמיתי: עם רק עשר קבוצות בסך הכל, כל קבוצה בודדת תורמת חלק לא זניח מהראיות לפריור-העל המשותף, כך שהסרת כל קבוצה, גם קטנה, משנה משמעותית את הפרמטרים המשותפים. זו בעיה מוכרת של השיטה הזאת במודלים היררכיים עם מעט קבוצות, ולא תלויה באיזו קבוצה ספציפית מדובר. הראיתי כאן בדיוק תהליך של בדיקה עצמית: ניחוש סביר, בדיקה בפועל, גילוי שהניחוש שגוי, והסבר טוב יותר על סמך הנתונים.

שאלתי את הצ'אט גם למה בכלל מדברים על "מספר אפקטיבי" של פרמטרים, ולא סופרים אותם ישירות:

Chat, why do we talk about the "effective" number of parameters in WAIC/LOO instead of just counting them?

והוא הסביר שבמודל ההיררכי, אחוזי ההצלחה של המחוזות מכווצים חלקית לכיוון הממוצע המשותף ולא חופשיים לגמרי להתאים את עצמם למחוז שלהם, כך שכל אחד תורם פחות מפרמטר שלם אחד למספר האפקטיבי. המודל ההיררכי יכול להיות בעל יותר פרמטרים על הנייר, כי הוא מוסיף את שני פרמטרי פריור-העל, אבל עם מספר אפקטיבי נמוך יותר מהמודל העצמאי, וזה בדיוק המנגנון שמאפשר לו להכליל טוב יותר. מדדים קלאסיים כמו AIC ו-BIC, שבנויים למודלים עם מספר פרמטרים קבוע וברור, לא יודעים להתמודד עם החישוב הזה, ולכן הם לא הכלי הסטנדרטי להשוואת מודלים בייסאניים היררכיים.

סיכום

לסיכום כל ההשוואות שעברנו עליהן: אומדן נקודה, רווח אמון מול רווח סמך, מבחן השערות מול פקטור בייס, ומודל עצמאי מול היררכי. השורה התחתונה: על המחוז הבודד שבחרנו לדוגמה הראשית, עם מספיק תצפיות, שתי הגישות מגיעות כמעט לאותה תוצאה, אבל ראינו במפורש, בסימולציה על מחוז קטן, באזהרת פקטור בייס, בסיפור המעבר בין המדדים, ובהשוואת שני המחוזות, שברגע שהמדגם קטן או שהשאלה מדויקת מספיק, יש הבדלים אמיתיים וניתנים למדידה בין שתי הגישות, ולא רק תיאורטיים.