

תסריט להקלטה למחברת 1: בייסאני מול קלאסי, אחוזי הצלחה בבתי ספר

משך משוער: כ-39-34 דקות בהקלטה בפועל (קריאה בקצב בינוני, ללא זמן המתנה על ריצת תאים).

פתיחה

במחברת הזאת אני עושה ניתוח בייסאני מול קלאסי של פרופורציות, כלומר "כמה אחוז מתוך קבוצה מצליחים במשהו".

השאלה שחוזרת לאורך כל המחברת פשוטה: מהו אחוז ההצלחה האמיתי של קבוצה נתונה, ואיך אומדים אותו מתוך הנתונים שיש? הרעיון המרכזי הוא לענות על השאלה הזו בשתי גישות שונות לגמרי, זו לצד זו: הגישה הקלאסית מניחה שהאחוז האמיתי הוא מספר קבוע אחד שפשוט לא ידוע, ומנסה לאמוד אותו; הגישה הבייסאנית מתייחסת לאותו אחוז עצמו כאל משתנה מקרי עם התפלגות אמון, ומעדכנת אותה ככל שרואים יותר נתונים. אני מריצה את שתי הגישות על אותו דאטה בדיוק, ומשווה תוצאות בכל שלב.

לצד ספריות העבודה הרגילות עם מספרים, טבלאות וגרפים, נטענים כאן גם הכלים הקלאסיים וגם הכלים הבייסאניים.

הדאטה עצמו

לפני שממשיכים, בואו נדבר קצת על הדאטה עצמו ומה הוא בכלל מייצג. המאגר שבחרתי, star98, הוא אוסף נתונים אמיתי על 303 מחוזות חינוך בקליפורניה, מובנה בתוך חבילת statsmodels בפיתוח ונוצר במקור כדי ללמד רגרסיה בינומית, בדיוק מה שעושים כאן. בכל מחוז, כל תלמידי כיתה מסוימת ניגשו למבחן קריאה סטנדרטי ארצי, ואנחנו יודעים כמה תלמידים ניקדו מעל החציון הארצי, וכמה ניקדו מתחתיו או בדיוק עליו. כלומר בשביל כל מחוז יש לנו בעצם תוצאה בינארית, עבר את החציון או לא, עבור כל אחד מהתלמידים שבו.

בנוסף לעמודות הקיימות, הוספתי כאן עוד שתי עמודות. העמודה הראשונה היא גודל המחוז הכולל, שהוא פשוט סכום התלמידים שעברו ושלא עברו, והעמודה השנייה היא אחוז ההצלחה, שהוא היחס ביניהם. הטבלה שמופיעה כאן מציגה סטטיסטיקה תיאורית לארבע העמודות האלה: כמות התצפיות, ממוצע, סטיית תקן, מינימום, מקסימום ואחוזונים. כבר בטבלה הזאת אפשר לראות פיזור עצום בגודלי המחוזות: מחוז אחד עם רק שלושים ושלושה תלמידים, ומחוז אחר עם כמעט שלושים ותשעה אלף.

בנוסף לטבלה, יצרתי גם שתי היסטוגרמות שיכולות לעזור להבין את הנתונים בצורה יותר חזותית. בגרף השמאלי ציר ה-X הוא אחוז ההצלחה וציר ה-Y הוא כמה מחוזות נמצאים בכל טווח אחוזים, ורואים שרוב המחוזות מרוכזים סביב ארבעים עד חמישים אחוז הצלחה בערך. בגרף הימני ציר ה-X הוא הגודל של המחוז, וציר ה-Y שוב כמה מחוזות נמצאים בכל טווח: בגלל הפיזור העצום שכבר ראינו בטבלה, בחרתי להציג אותו בסקאלה לוגריתמית, כדי שאפשר יהיה לראות על אותו גרף גם את המחוזות הקטנים וגם את הגדולים. השוני העצום הזה בגודל הוא מרכיב מרכזי שישחק תפקיד בהמשך, כשנגיע לתופעה שנקראת כיווץ.

אנחנו מתחילים במחוז בודד אחד, ובודקים אותו דרך הגישה הקלאסית. לשם הדוגמה בוחרים במחוז שגודלו הכי קרוב לחציון, עם 445 תלמידים, וזאת רק כדי שהמספרים יהיו נוחים לעבודה, כי כל מחוז אחר היה עובד באותה מידה. את אחוז ההצלחה האמיתי שלו מסמנים ב- p , כמו שנכתוב בקוד בהמשך, וקודם מעריכים אותו מהנתונים ואז בודקים עד כמה אפשר לבטוח באומדן שמתקבל.

התא הזה עושה כמה דברים ברצף: מוצא את המחוז שגודלו הכי קרוב לחציון, ואז בונה ממנו וקטור פשוט של אפסים ואחדים, אחת לכל תלמיד שעבר ואפס לכל תלמיד שלא עבר, ומערבב את הסדר ביניהם באקראי (הסדר לא משנה לחישוב שנעשה איתם בהמשך, זה רק כדי שהוקטור ייראה כמו רצף אמיתי ולא כאילו כל העוברים מרוכזים בהתחלה), ואלה בדיוק הנתונים האמיתיים שנרשמו לכל תלמיד באותו מחוז, לא סימולציה.

הממוצע הפשוט של הנתונים האלה, שבקוד נקרא $\hat{p}$ ויוצא סביב 0.62, הוא אומדן הנקודה הקלאסי של p , כלומר הניחוש הכי טוב שיש לנו כרגע אליו, ועליו נבנים מיד רווחי הסמך הבאים.

יש כאן שלושה סוגי רווחי סמך קלאסיים של 95 אחוז, כל אחד בשמו. הראשון, רווח וולד (Wald), הנוסחה הכי סטנדרטית מהספר, מבוסס על כך שלפי משפט הגבול המרכזי, האומדן מתפלג בקירוב נורמלי סביב הערך האמיתי, כך שרוב שטח ההתפלגות הנורמלית נמצא בטווח צר סביב הממוצע. השני, רווח בוטסטרפ, מבוסס על עיקרון שונה לגמרי: יש לי כמה מאות תוצאות אמיתיות, ואני מדמה מדגמים חדשים על ידי דגימה מחדש בהחזרה מתוך אותם הערכים בדיוק, כלומר בוחרים באקראי אותו מספר פעמים, כשכל תצפית מקורית יכולה להיבחר שוב או לא להיבחר כלל, מחשבים את האומדן על המדגם המדומה, וחוזרים על זה אלפי פעמים. הפיזור של כל האומדנים האלה מדמה את הפיזור שהיינו רואים אם באמת חזרנו ואספנו מדגמים חדשים, וממנו לוקחים את התחום שמכיל 95 אחוז מהערכים. השלישי, רווח וילסון (Wilson), נוסחה פחות מוכרת אבל יותר מדויקת במדגמים קטנים: במקום להניח סימטריה סביב האומדן כמו וולד, היא פותרת משוואה שמכניסה את הערך האמיתי הלא-ידוע p לתוך הנוסחה עצמה, וכך מתקבל רווח שלא בהכרח סימטרי, אבל מתנהג טוב יותר גם כש- n קטן וגם כש- p קרוב לאפס או לאחת. שלושת הרווחים יוצאים כאן כמעט זהים.

כדי להבין את ההבדל הפילוסופי בין שתי הגישות, שאלתי את הצ'אט:

Chat, discuss the differences between Bayesian and frequentist statistics, using this example of estimating a school's pass rate.

והוא ענה שהגישה הקלאסית מתייחסת לאחוז ההצלחה האמיתי, p , כמספר קבוע לא ידוע (לא $\hat{p}$, שהוא האומדן המחושב שכבר יש לנו), ורווח הסמך הוא בעצם אמירה על התהליך, לא על הערך עצמו: אם היינו חוזרים על הדגימה הרבה פעמים, ב-95 אחוז מהפעמים הרווח היה מכיל את הערך האמיתי. הגישה הבייסאנית, לעומת זאת, הופכת את הערך עצמו למשתנה מקרי, ואז אפשר להגיד ישירות שיש 95 אחוז סיכוי שהוא בטווח הזה. זהו הבדל אמיתי בין אמירה על תהליך לאמירה ישירה על הפרמטר.

רווח וולד, למרות שהוא הכי מוכר, נשען על קירוב שנחלש במדגמים קטנים או באחוזים קיצוניים. כדי לבדוק אם אפשר לסמוך עליו במקרה כזה, בניתי סימולציה: מחוז קטן היפותטי עם ארבעים תלמידים ואחוז הצלחה נמוך, ואלפי הדמיות חוזרות, שבכל אחת מהן נבנה רווח סמך חדש ונבדק אם הוא מכיל

את הערך האמיתי. וולד כיסה את האמת רק ב-86.2 אחוז מהפעמים, במקום 95 אחוז שהוא מבטיח. וילסון, נוסחה פחות מוכרת, הגיע ל-94.1 אחוז, קרוב מאוד להבטחה. (בוטסטרפ לא נכלל בסימולציה, כי הרצה שלו אלפי פעמים יקרה מדי חישובית).

התשובה הבייסאנית: פריור בטא

עכשיו חוזרים לאותה שאלה בדיוק, מהו p האמיתי של המחוז, אבל הפעם דרך הגישה הבייסאנית. לפני שראיתי נתונים, אני לא יודעת כלום על אחוז ההצלחה מלבד שהוא בין אפס לאחת, וזה בדיוק פריור בטא עם שני הפרמטרים שווים לאחת, שהוא בעצם התפלגות אחידה. בגרף שמראה אותו, ציר ה- X הוא הערך האפשרי של p , בין אפס לאחת, וציר ה- Y הוא צפיפות ההסתברות, ויוצא קו ישר אופקי, כי כל ערך אפשרי סביר באותה מידה מראש.

שני השלבים הבאים של חוק בייס מופיעים כאן כנוסחאות. אם אחוז ההצלחה האמיתי הוא x , ההסתברות שתלמיד בודד עובר את הרף היא x , וכל התלמידים בלתי-תלויים זה בזה, ולכן הלייקליהוד, ההסתברות לראות בדיוק את הנתונים שראינו בהינתן ש- x הוא הערך האמיתי, הוא מכפלת כל התוצאות הבודדות, וזה בדיוק מה שהופך אותו להתפלגות בינומית, כמו שרואים בנוסחה הראשונה. ולפי חוק בייס עצמו, הפוסטרירי, ההסתברות של p בהינתן הנתונים, פרופורציונלי למכפלת הלייקליהוד בפריור, בדיוק כמו שכתוב בנוסחה השנייה. שתי הנוסחאות האלה הן בדיוק מה שמאפשר לעבור מהקו השטוח של הפריור לעקומה הצרה של הפוסטרירי שנראה עוד רגע.

הגרף כאן מראה שתי עקומות: הפריור השטוח, ולידו הפוסטרירי אחרי שראינו את הנתונים, ועליהן קו מקווקו אנכי שמסמן את $\hat{p}$, אותו אומדן קלאסי שכבר חישבנו קודם. חשוב להבין מה שתי העקומות האלה בעצם אומרות, לא רק איך הן נראות. הקו השטוח של הפריור אומר: לפני שראיתי אפילו תלמיד אחד מהמחוז הזה, כל ערך אפשרי נראה לי סביר באותה מידה בדיוק, אין לי שום מושג אם המחוז מצליח או נכשל. העקומה הצרה והממוקדת של הפוסטרירי אומרת: אחרי שראיתי את הנתונים, אני עכשיו כמעט בטוחה שאחוז ההצלחה האמיתי של המחוז נמצא באזור צר סביב 0.62, וערכים קיצוניים הפכו בלתי סבירים כמעט לגמרי. שווה לשים לב שהקו המקווקו של $\hat{p}$ נופל כמעט בדיוק בשיא הפוסטרירי: זה לא מקרי, אלא בדיוק מה שקורה כשיש מספיק נתונים ופריור חלש, כמו כאן. זו בדיוק המשמעות של עדכון אמונות לפי נתונים: התמונה עברה מבורות מוחלטת לביטחון ממוקד, וזה בדיוק מה שהגרף מראה חזותית.

אחרי שראיתי את העדכון הזה קורה בפועל, שאלתי את הציאט למה דווקא התפלגות בטא היא הבחירה הטבעית כאן:

Chat, why is the Beta distribution the natural conjugate prior for a Binomial likelihood?

והוא ענה שזה נובע מכך שהצורה האלגברית של הלייקליהוד הבינומי זהה לצורה של צפיפות בטא, ולכן הכפל ביניהן רק מוסיף מעריכים. זה בדיוק מה שנקרא פריור צמוד: אחרי שרואים כמה הצלחות מתוך כמה ניסיונות, הפוסטרירי הוא שוב בטא, רק עם פרמטרים מעודכנים בחיבור פשוט, בלי שום אינטגרציה נומרית.

כדי לממש את המודל הבייסאני הזה בפועל, עברתי לכתוב אותו בקוד, בעזרת הספרייה pymc. כאן עשיתי משהו קצת שונה ממה שהיה מתבקש להעתיק ישירות: במקום לייצג כל תלמיד כשורה נפרדת, אני משתמשת בפונקציה שמייצגת ישירות את הספירה המצטברת של הצלחות מתוך סך הניסיונות. בפועל השורה הזאת מגדירה בתוך המודל משתנה חדש, ואומרת עליו שני דברים בבת אחת: ראשית, שהוא מתפלג בינומית עם מספר הניסיונות של המחוז והסתברות ההצלחה שהגדרנו שורה קודם עם הפריור ושנית, שהוא נצפה בערך ספציפי, כלומר לא צריך לדגום אותו בכלל, כי אנחנו כבר יודעים בוודאות מה הוא שווה, זה מה שבאמת קרה במחוז הזה. השילוב הזה הוא בדיוק מה שמחבר את הדאטה למודל: כך המערכת מחשבת, לכל ערך היפותטי של אחוז ההצלחה, כמה סביר היה לראות בדיוק את התוצאה שראינו, אילו הערך היה שווה לו, וזה בדיוק הלייקליהוד שנכנס לחוק בייס. בלי השורה הזאת, למודל לא הייתה שום דרך לפגוש את הנתונים האמיתיים בכלל.

לפני שדוגמים בכלל, יש כאן דיאגרמה גרפית של מבנה המודל עצמו: עיגול פתוח לפרמטר הנסתר, עם חץ שיוצא ממנו לתוך עיגול מוצל שמייצג את מה שנצפה בפועל.

כדאי לעצור כאן רגע ולהסביר למה בכלל דוגמים, הרי בדיוק ראינו שיש לפוסטריורי הזה נוסחה סגורה מדויקת. התשובה: לא חייבים כאן, אבל מריצים את הדגימה בכל זאת בכוונה, כדי לבדוק את הכלי הכללי על מקרה שבו כבר יודעים מה התשובה הנכונה אמורה לצאת, לפני שמשתמשים בו בהמשך על מודלים שבאמת אין להם נוסחה סגורה, כמו המודל ההיררכי שנראה בהמשך. שם, בלי דגימה, לא הייתה שום דרך לקבל תשובה בכלל. הרעיון של הדגימה עצמה: כשאי אפשר לחשב את הפוסטריורי במדויק, דוגמים ממנו הרבה פעמים במקום, כך שההתפלגות של הדגימות תדמה לצורה האמיתית. זה בדיוק מה שדגימת שרשראות מרקוב מונטה קרלו עושה, והאלגוריתם הספציפי כאן משתמש בשיפוע של הפוסטריורי כדי לדעת לאן לזוז, וכך מתקדם הרבה יותר מהר מניחוש אקראי גרידא.

יש כאן ארבע שרשראות בלתי תלויות שרצות במקביל, כל אחת מנקודת התחלה אחרת, ואם כולן מתכנסות לאותה התפלגות זו עדות חזקה שאנחנו רואים את הפוסטריורי האמיתי ולא תקלה מקומית. לכל שרשרת יש שלב חימום שנזרק ולא נספר, ורק אחריו מתחילים לספור את הדגימות שנשמרות בפועל.

בגרף מסלול הדגימה כאן, ציר ה-X הוא מספר הדגימה, ציר ה-Y הוא הערך שנדגם, וארבעה קווי צבע, אחד לכל שרשרת. שרשרת שמתפקדת טוב נראית כמו רעש אקראי צפוף סביב אותו פס צר לאורך כל הציר, בלי לזוז בהדרגה לכיוון מסוים (מגמה) ובלי להישאר תקועה על אותו ערך לאורך זמן. חשוב לא פחות: ארבעת הקווים צריכים להיראות כאילו הם רועשים באותו אזור בדיוק וחופפים זה על זה כמעט לגמרי, וזה הסימן החזותי שכל השרשראות, למרות שהתחילו מנקודות שונות, הגיעו לאותה מסקנה. מבחינה מתמטית, קידוד הנתונים כספירה מצטברת אמור לתת פוסטריורי זהה לחלוטין לקידוד של כל תלמיד בנפרד, בזכות עיקרון שנקרא מספיקות סטטיסטית, אבל לא הסתפקתי בטענה הזו, ושאלתי את הציאט אם אפשר להראות את זה ולא רק להצהיר:

Chat, is the pm.Binomial encoding really identical to a per-student pm.Bernoulli array? Show me, don't just assert it.

והוא אישר את זה, אבל הציע לא להסתפק בטענה תיאורטית, אלא להראות את זה בפועל: כדי לדעת כמה שאפשר על אחוז ההצלחה, לא צריך לדעת את הסדר המדויק שבו הצליחו ונכשלו התלמידים, צריך לדעת רק כמה בסך הכל עברו, כי הסכום הזה הוא תמצית שמכילה בתוכה את כל המידע. הדרך להראות

את זה בפועל היא להריץ את שני הקידודים על אותם נתונים בדיוק ולהשוות את הפוסטריורים המתקבלים במספרים.

עשיתי בדיוק את זה: הרצתי גם את הגרסה שמייצגת כל תלמיד בנפרד, על אותו הווקטור המקורי, והשוויתי את שני הפוסטריורים במספרים: הממוצע הפוסטריורי יוצא זהה בשני המקרים עד כדי הבדל זניח ברעש הדגימה, וכך גם סטיית התקן. טענת המספיקות לא נשארה טענה תיאורטית, נבדקה ואומתה. שווה גם לחשוב רגע מה היה משתנה אילו השתמשתי במערך המלא של כל תלמיד בנפרד במקום בספירה המצטברת: הפוסטריורי המתקבל היה זהה לגמרי בזכות המספיקות שכבר בדקנו, אבל כל צעד של האלגוריתם היה צריך לחשב מאות הסתברויות בנפרד במקום הסתברות בינומית אחת, כך שזה היה הרבה יותר איטי, בלי לשנות את התשובה בכלל.

רווחי אמון מול רווחי סמך: השוואה ישירה

אחרי שיש לנו גם דגימות מהפוסטריורי המלא, אפשר סוף סוף להשוות ישירות בין רווח האמון הבייסאני לשלושת רווחי הסמך הקלאסיים. הגרף הזה מראה את הפוסטריורי דרך עקומת צפיפות, קו לאומדן הנקודה, ותחום מוצלל לרווח האמון של 95 אחוז.

בתא שאחרי הגרף מופיעה טבלת סיכום סטנדרטית של arviz, שמראה עבור p את הממוצע הפוסטריורי, סטיית התקן, וגבולות רווח האמון, לצד כמה עמודות אבחון שיחזרו לאורך כל המחברת וכדאי להסביר פעם אחת כאן: `ess_bulk` ו-`ess_tail` הם גודל המדגם האפקטיבי, כלומר כמה דגימות בלתי-תלויות שוות-ערך יש לנו בפועל מתוך דגימת ה-MCMC של p (זו הדגימה שהגישה הבייסאנית מבצעת), ולא כמה דגימות יש על הנייר; ו-`r_hat` הוא מדד ההתכנסות של גלמן-רובין, שמשווה את השונות בין השרשראות השונות לשונות בתוך כל שרשרת בנפרד. ערך קרוב מאוד לאחת, כמו שרואים כאן, אומר ששרשראות שהתחילו מנקודות התחלה שונות התכנסו לאותה התפלגות בדיוק; ערך גבוה משמעותית מאחת הוא אזהרה שדגימת p לא באמת התכנסה ואי אפשר לסמוך על התוצאה. מתחת לטבלה הזו, באותו פלט, מודפסים גם ארבעת רווחי הסמך שכבר חישבנו.

עכשיו הרגע המרכזי: כל ארבעת הרווחים, שלושת הקלאסיים ורווח האמון הבייסאני, מופיעים אחד מתחת לשני באותו גרף. כל אחד מהם מצויר כקו אופקי שמתחיל בגבול התחתון של אותו רווח ומסתיים בגבול העליון שלו, כך שאורך הקו על הגרף מראה חזותית כמה רחב הרווח הזה. עבור המחוז הזה, עם מדגם בגודל בינוני ופריור שטוח, כל הארבעה כמעט זהים לגמרי, בדיוק כמו שהתאוריה הא-סימפטוטית מנבאת. אבל, כפי שראינו קודם, זה לא תמיד המצב במחוזות קטנים.

מבחן השערות: פקטור בייס מול מבחן קלאסי

עד כה השאלה הייתה כמה גבוה אחוז ההצלחה. עכשיו שאלה מסוג אחר: האם המחוז שלנו שונה מהממוצע הארצי, שיוצא סביב 44 אחוז? כמו שאתם יכולים לראות, הגישה הקלאסית עונה על זה עם מבחן בינומי מדויק, שנותן כאן ערך מובהקות זעיר. שאלתי את הצ'אט מה הגישה הבייסאנית המקבילה:

Chat, what's the Bayes factor and how does it compare to a classical significance test here? What are H_0 and H_1 , and how does arviz compute it?

והוא ענה שהגישה הבייסאנית המקבילה היא פקטור בייס. בעוד שערך המובהקות של המבחן הקלאסי הוא ההסתברות לראות נתונים קיצוניים כאלה בהינתן ש- H_0 נכונה בדיוק, פקטור בייס משווה ישירות את העדות בעד H_0 מול העדות בעד H_1 , ומודד כמה פעמים יותר סביר לראות את הנתונים שראינו תחת השערה אחת לעומת השנייה. H_0 כאן הוא שאחוז ההצלחה של המחוז שווה למוצע הארצי, ו- H_1 שהוא שונה ממנו. הוא מחושב בשיטה שנקראת יחס Savage-Dickey: משווים את צפיפות הפוסטריורי לצפיפות הפריור, שתייהן בדיוק בערך הייחוס, כלומר בנקודה שמייצגת את H_0 , הממוצע הארצי.

כדי להמחיש את פקטור בייס, בגרף הזה: ציר ה- X הוא אחוז ההצלחה וציר ה- Y הוא צפיפות ההסתברות, עם שתי עקומות על אותם צירים, אחת לפריור ואחת לפוסטריורי, וקו אנכי מסמן את ערך הייחוס. פקטור בייס הוא בדיוק היחס בין גובה שתי העקומות באותה נקודה על הקו האנכי, וזה הערך שהכותרת של הגרף מדפיסה: כאן הוא יוצא 38.52, כלומר הנתונים שראינו סבירים פי כ-38.5 יותר תחת ההשערה שהמחוז שונה מהממוצע הארצי לעומת ההשערה שהוא שווה לו.

וכאן קרה משהו אמיתי שכדאי לספר עליו: כשהרצתי את התא, קפצה אזהרה מהספרייה שאומרת שערך הייחוס נמצא מחוץ לטווח הפוסטריורי, ושזה עלול להגזים בעדות בעד ההשערה. זו בדיוק המלכודת שהקורס שואל עליה, וקיבלתי אותה בפועל, לא רק בתיאוריה. ההסבר: הפוסטריורי של המחוז הזה נמצא הרחק מהממוצע הארצי, וכשערך הייחוס רחוק מהתחום שיש בו בכלל דגימות, אומדן הצפיפות צריך לנחש את הערך שם, וזה לא אמין. אני מציינת בפירוש שהמספר של פקטור בייס כאן פחות אמין, אבל הכיוון שלו, שהמחוז שונה משמעותית מהממוצע הארצי, נתמך גם על ידי ערך המובהקות הזעיר של המבחן הקלאסי.

שאלתי את הצ'אט גם איך לפרש את הגודל של פקטור בייס, ולמה הוא ומבחן קלאסי יכולים לסתור זה את זה:

Chat, how should I interpret the Bayes factor value above, and why might it disagree with the p-value?

והוא ענה שיש סולם מקובל שממין אותו מ"כמעט לא משמעותי", כשהמספר בין 1 ל-3, ועד "מכריע", כשהמספר מעל 100. בנוסף הוא הסביר שזה יכול לסתור את ערך המובהקות, כיוון שעם מדגם גדול ערך המובהקות יכול לצאת קטן גם על הבדל זניח, בעוד פקטור בייס נשאר זהיר יותר. המצב הזה נקרא הפרדוקס של לינדלי, והוא הבדל מבני אמיתי בין שתי הגישות, לא טעות.

אומדני בייס: ממוצע וחציון

יש לי כבר את הפוסטריורי המלא של המחוז, אבל לפעמים רוצים לדווח מספר יחיד במקום התפלגות שלמה. שאלתי את הצ'אט מה ההבדל בין אומדן נקודה רגיל לאומדן בייס, ואיזו פונקציית אובדן עומדת מאחורי כל אחד:

Chat, what's the difference between a point estimate and a Bayes estimator, and which loss function corresponds to the posterior mean vs. the posterior median?

והוא ענה שאומדן נקודה הוא בסך הכול כל מספר בודד שמסכם את הפוסטריורי, ואילו אומדן בייס הוא מונח ממוקד יותר: הערך שממזער את האובדן הפוסטריורי הצפוי, לפי פונקציית אובדן שבחרים מראש. הממוצע הפוסטריורי ממזער שגיאה ריבועית, החציון ממזער שגיאה מוחלטת, והשכיח ממזער אובדן

אפס-אחד. שלושת האומדנים האלה יוצאים כמעט זהים כשהפוסטריורי סימטרי וחד-שיאי, כמו כאן, אבל יכולים להיבדל משמעותית כשהוא מוטה, למשל במחוז עם מעט מאוד תלמידים ואחוז הצלחה קרוב לאפס, שם הבטא הפוסטריורית יוצאת מוטה בבירור.

בגרף הזה: ציר ה-X הוא ערך מועמד לאומדן, בין אפס לאחת, וציר ה-Y הוא האובדן הצפוי אילו בחרנו בערך הזה: שתי עקומות, אחת ל-L2 ואחת ל-L1, ונקודה שמסמנת את המינימום של כל אחת. המינימומים האלה חופפים בדיוק לממוצע ולחציון של הפוסטריורי שכבר חישבתי קודם, בדיוק כמו שהתיאוריה מבטיחה.

התפלגות חיזוי פוסטריורית

מעבר לאמידת הפרמטר עצמו, אפשר גם לשאול מה צפוי לקרות בעתיד. שאלתי את הציאט מה בכלל ההבדל בין הפוסטריורי לבין התפלגות חיזוי פוסטריורית:

Chat, what's the difference between the posterior and the posterior predictive distribution, using this district as the example?

והוא הבהיר שהפוסטריורי מתאר את האמון שלנו על הפרמטר עצמו, ואילו התפלגות החיזוי מתארת תחזית לתצפית חדשה, כמו כמה תלמידים היו עוברים אילו בדקנו עוד קבוצה מאותו מחוז. התפלגות החיזוי כוללת גם את אי-הוודאות על הפרמטר וגם את השונות האקראית הרגילה של דגימה חדשה, ולכן היא תמיד רחבה יותר מהתפלגות דגימה סביב ערך יחיד בלבד של הפרמטר.

ההיסטוגרמה הזאת: ציר ה-X הוא מספר תלמידים שהיו עוברים את הרף בהדמיה אחת, וציר ה-Y הוא כמה מבין אלפי ההדמיות נתנו כל מספר כזה. קו אנכי מסמן את המספר שבאמת נצפה בפועל באותו מחוז, והוא נופל בדיוק בתוך תחום הצפיפות הגבוהה של ההיסטוגרמה, כלומר המודל היה "מופתע" רק מעט מהתוצאה האמיתית, סימן בריא.

הרבה מחוזות: מודל עצמאי

עכשיו החלק המרכזי השני, ועכשיו השאלות קצת שונות: האם המחוזות דומים בממוצע? האם כל מחוז שונה מהאחרים? האם מחוז ספציפי שונה ממחוז אחר? והאם כולם בכלל מגיעים מאוכלוסייה משותפת אחת? כל 303 המחוזות עברו את אותו מבחן ארצי, אז יש הצדקה סבירה להתייחס אליהם כבאים מאותה יציקה, בדיוק כמו הרעיון של כמה מטבעות מאותו בית מטבעות. בוחרת עשרה מחוזות שפרוסים בכוונה על פני כל טווח הגדלים, כי בדיוק השוני הזה הופך את תופעת הכיווץ לגלויה. בטבלה כאן רואים את ספירת ההצלחות, ספירת הכישלונות, הגודל הכולל, ואחוז ההצלחה של כל אחד מהם.

במודל העצמאי, לכל מחוז יש אחוז הצלחה משלו, לגמרי בלתי תלוי באחרים. שוב יש כאן דיאגרמת מודל: עיגול פתוח אחד לפרמטר ההצלחה, אבל הפעם הוא מסומן כמערך של עשרה ערכים ולא ערך בודד, אחד לכל מחוז בתת-הקבוצה, וכולם מזינים חץ לתוך התצפיות. בטבלת הסיכום, המחוז הקטן ביותר יוצא עם רווח אמון רחב יחסית, כי יש לו מעט מאוד תלמידים, בעוד מחוז גדול יותר יוצא עם רווח הרבה יותר צר.

בטבלה יש כבר את ערך ה- $\hat{r}$ שכבר הסברתי קודם, אבל עם עשרה פרמטרים כדאי גם לראות את זה חזותית ולא רק להסתמך על המספר בטבלה. יש כאן גרף מסלול נפרד לכל אחד מעשרת המחוזות: בכל פאנל ציר ה-X הוא מספר הדגימה וציר ה-Y הוא אחוז ההצלחה שנדגם, וארבעה צבעים לארבע

השרשראות. בכל אחד מעשרת הפאנלים ארבעת הצבעים חופפים לגמרי לרעש חסר מבנה, בדיוק כמו במחוז הבודד שראינו קודם, כלומר ההתכנסות נראית תקינה לא רק במספר אלא גם חזותית, על כל אחד מהפרמטרים בנפרד.

השוואת שני מחוזות ספציפיים: מבחני קונטינגנטיות מול הפרש פוסטריורי

עד כה כל השוואה במחברת הייתה על פרופורציה בודדת אל מול ערך ייחוס קבוע. שאלה נפוצה לא פחות היא האם שני מחוזות ספציפיים שונים ממש זה מזה, וזו בעיה קלאסית של טבלת קונטינגנטיות: מחוז כפול עבר-או-לא-עבר. בוחרת את שני המחוזות עם ההבדל הכי בולט באחוז ההצלחה שלהם, אחד חזק מאוד ואחד חלש יחסית. לפני שמריצה את המבחנים, שאלתי את הצ'אט על עקרון מבחן פישר המדויק:

Chat, what's the test statistic in Fisher's exact test, and why are its "marginals" fixed?

והוא הסביר שמבחן פישר המדויק מתנה על כך ששני סוגי הסכומים בטבלה, סך התלמידים בכל מחוז וסך העוברים הכולל, קבועים, ומחשב את ההסתברות המדויקת, לפי התפלגות היפרגאומטרית, שתתקבל טבלה קיצונית לפחות כמו זו שנצפתה. מכאן השם "מדויק", כי אין כאן שום קירוב למדגם גדול. קיבוע הסכום של כל מחוז טבעי כאן, כי זה פשוט מספר התלמידים בו ולא משהו אקראי. קיבוע הסכום הכולל נוח יותר מבחינה מתמטית מאשר הנחה מהותית, אבל זו הפרקטיקה הסטנדרטית, והמבחן מתלכד היטב עם מבחן חי-בריבוע כל עוד התאים הצפויים בטבלה לא זעירים.

הרצתי את שני המבחנים, מבחן פישר המדויק ומבחן חי-בריבוע, על הטבלה של שני המחוזות האלה, וקיבלתי בשניהם ערכי מובהקות זעירים ביותר, מה שלא מפתיע לאור פער של קרוב לחמישים נקודות אחוז בין שני מחוזות עם אלפי תלמידים משותפים. שאלתי גם מה זה אומדן יחס הסיכויים, ומה ההנחות של מבחן חי-בריבוע:

Chat, what's an odds ratio, and what are the assumptions of the chi-squared test here?

והוא הסביר שיחס הסיכויים משווה את סיכויי ההצלחה במחוז אחד לסיכויי ההצלחה במחוז השני, וערך רחוק מאחת אומר ששני המחוזות שונים משמעותית באחוז ההצלחה שלהם. השערת האפס של שני המבחנים היא בדיוק שיחס הסיכויים שווה אחת, כלומר ששני המחוזות חולקים את אותו אחוז הצלחה אמיתי. מבחן חי-בריבוע דורש בנוסף שהתא הצפוי בכל משבצת בטבלה יהיה גדול דיו, כלל אצבע נפוץ הוא לפחות חמישה, ועם שני מחוזות בגודל כזה ההנחה הזאת מתקיימת בנוחות, ולכן שני המבחנים כאן מתלכדים כל כך.

עכשיו הצד הבייסאני של אותה שאלה: במקום מבחן בודד עם ערך מובהקות אחד, יש לנו כבר פוסטריורי מלא לשני המחוזות ממודל העצמאי, כך שאפשר להסתכל ישירות על ההפרש בין שני הפוסטריורים. רווח האמון של 95 אחוז על ההפרש יוצא רחוק מאוד מאפס בשני הכיוונים, בהתאמה מלאה לדחייה הנחרצת של שני המבחנים הקלאסיים. אבל השורה האחרונה שם היא סוג שונה לגמרי של אמירה: ההסתברות הפוסטריורית שהמחוז החזק באמת עולה על החלש יוצאת קרוב לוודאות מוחלטת, וזו אמירת הסתברות ישירה על השאלה שבאמת מעניינת אותנו, שמחושבת מהדגימות שכבר היו לנו, בלי צורך במבחן נפרד. ערך מובהקות, לעומת זאת, מבחינה מבנית לא יכול להתפרש כהסתברות שהשערת האפס נכונה: הוא ההסתברות לנתונים קיצוניים כאלה בהינתן שהשערת האפס נכונה, שאלה שונה ומסורבלת יותר מזו שבדרך כלל רוצים לענות עליה בפועל.

המודל העצמאי לא מנצל בכלל את זה שכל המחוזות שייכים לאותה מדינה ואותו מבחן ארצי. המודל ההיררכי הבא מתקן בדיוק את זה: מוסיפים שכבה משותפת, פריור-על על הממוצע האוכלוסייתי, ופרמטר נוסף שמבטא כמה ריכוז יש סביב הממוצע הזה, כמו גודל מדגם דמיוני. כל מחוז מקבל אחוז הצלחה משלו, אבל הוא נשלף מהתפלגות בטא שהפרמטרים שלה עצמם משותפים לכולם, כך שמידע זולג בין המחוזות. שוב יש כאן דיאגרמה, וההבדל הוויזואלי מהמודל העצמאי בולט מיד: יש שני עיגולים נוספים שמזינים חץ לתוך הפרמטר, במקום שהוא יקבל מספרים קבועים כהורים שלו.

אחרי הדגימה, הממוצע האוכלוסייתי המשותף יוצא סביב 0.38, ופרמטר הריכוז יוצא סביב 9.6. מה זה אומר בפועל? ש-38 אחוז הוא בערך אחוז ההצלחה הטיפוסי שממנו כל המחוזות בקבוצה סוטים, ושהריכוז הקטן יחסית, בהשוואה למחוזות עם מאות או אלפי תלמידים, אומר שהמודל לא בטוח שכל המחוזות דומים מאוד זה לזה: הוא מרשה למחוזות לסטות באופן משמעותי מהממוצע המשותף, לא כופה עליהם להיות כמעט זהים. פרמטר ריכוז גדול הרבה יותר היה אומר שכל המחוזות כמעט זהים וכל סטייה היא רעש בלבד, וזה לא המצב כאן.

שאלתי את הצ'אט למה משתמשים בפרמטריזציה הזאת, ממוצע אוכלוסייתי וריכוז, במקום שני הפרמטרים הרגילים של בטא:

Chat, why is the $\text{Beta}(\mu, \nu)$ parametrization used here instead of $\text{Beta}(\alpha, \beta)$, and what does ν mean?

והוא הסביר שאלפא ובטא לא ניתנים לפירוש ישיר במונחים שקל לחשוב עליהם, ואילו הפרמטריזציה של מיו ונו כן: מיו הוא הממוצע, ונו הוא בערך "גודל מדגם דמיוני" שקובע כמה צר הפריור סביב הממוצע, כך שנו גדול יותר אומר התפלגות צרה יותר. זה מאפשר לשים פריור-על ישירות על הממוצע האוכלוסייתי ועל מידת השונות המותרת בין מחוזות, וזה בדיוק המנגנון שמאפשר זרימת מידע בין המחוזות בזמן הדגימה.

גם כאן, עם עשרה פרמטרים במודל ההיררכי, כדאי לבדוק התכנסות חזותית ולא רק להסתפק בטבלה. הפעם הכלי הוא אחר, שמתאים יותר להציג הרבה פרמטרים יחד: גרף יער, שבו ציר ה-Y הוא עשרת המחוזות וציר ה-X הוא אחוז ההצלחה המוערך; בכל שורה יש ארבעה קווי שגיאה חופפים, אחד לכל שרשרת, כל אחד עם נקודה שמסמנת את האומדן שלו ורווח סביבו. ככל שארבעת הקווים בכל שורה חופפים חזק יותר זה על זה, כך יש יותר הסכמה בין השרשראות, שוב בדיוק סימן חזותי להתכנסות. מיו ונו לא מופיעים בגרף הזה בכוונה: הסקאלה שלהם שונה לגמרי מזו של אחוזי ההצלחה, וגרף אחד עם שני הסוגים ביחד היה הופך את הרווחים של המחוזות לבלתי נראים.

כיווץ

הגענו לתופעה שכבר הזכרתי בהתחלה, כשדיברנו על השוני בגודל בין המחוזות: כיווץ. שאלתי את הצ'אט מה זה בעצם, ואיך המודל ההיררכי יוצר אותו:

Chat, what is shrinkage, and how does the hierarchical model produce it here?

והוא הסביר שבמודל העצמאי, לכל מחוז יש רק את הנתונים שלו, ומחוז עם מעט תלמידים מקבל פוסטריוירי רחב ולא בטוח. במודל ההיררכי, כל מחוז גם נמשך לכיוון הממוצע המשותף, וחוזק המשיכה תלוי כמה נתונים יש למחוז הזה עצמו: מחוזות קטנים נמשכים חזק, מחוזות גדולים כמעט ולא זזים, כי הנתונים שלהם כבר גוברים על ההשפעה המשותפת. זה בדיוק המנגנון של אומדן גיימס-שטיין, מנגנון סטטיסטי קלאסי ומפורסם, רק שכאן הוא יוצא באופן טבעי ממבנה המודל ההיררכי, בלי שהיה צריך להמציא אותו בנפרד.

השוואת מודלים: מ-WAIC ל-LOO

עכשיו יש לי שני מודלים בייסאניים לאותו דאטה, העצמאי וההיררכי, ואיך בכלל בוחרים ביניהם? הם לא מקוונים, כלומר אי אפשר לצמצם את ההיררכי לעצמאי פשוט על ידי איפוס פרמטר, כך שמבחן יחס-נראות קלאסי לא רלוונטי כאן, וגם פקטור בייס בין שני מודלים כאלה דורש נראות שולית שקשה מאוד לחשב בפועל. הכלי הסטנדרטי במקרה כזה הוא מדד מבוסס נראות-חיזוי-מקומית.

נקודה שחשוב לספר עליה בקול, כי היא בדיוק דוגמה לגרסה של ספרייה שהשתנתה: כתבתי במקור את הקוד בדיוק כמו שהנראות הקורס מציגות, עם המדד הישן שנקרא WAIC, וקיבלתי שגיאה שאין פרמטר כזה. מסתבר שהגרסה העדכנית של הספרייה הסירה לגמרי את האפשרות לבחור במדד הישן, ועברה כברירת מחדל למדד חדש שנקרא LOO, מבוסס אימות בהוצאה-אחת-בכל-פעם. הרעיון: הדרך הנכונה לבדוק כמה טוב מודל היא להוציא כל תצפית בתורה, לאמן מחדש בלעדית, ולבדוק כמה טוב המודל חוזה את מה שהוצא, אבל לאמן מחדש עשר פעמים, ובוודאי שלוש פעמים, עם דגימת שרשראות מרקוב, יקר מדי בפועל. הפתרון החכם הוא לא לאמן מחדש בפועל, אלא לשקלל מחדש את הדגימות שכבר יש לנו, כך שהן מדמות איך היה נראה הפוסטריוירי בלי התצפית הזאת. היתרון על המדד הישן: יש למדד החדש בדיקת תקינות מובנית שמזהה בדיוק מתי השקלול הזה לא אמין, ולמדד הישן אין דבר כזה.

בטבלת ההשוואה: המודל ההיררכי מדורג ראשון, ההפרש שלו מוגדר כאפס כבסיס להשוואה, והמודל העצמאי מדורג שני, גרוע יותר ביחידת ניקוד אחת בערך, אבל עם שגיאה תקנית של ההפרש שגדולה יחסית להפרש עצמו, כלומר ההבדל הזה קטן ביחס לרעש שלו, לא הבדל דרמטי. עמודת המשקל נותנת משקל מלא להיררכי ואפס לעצמאי, אם רוצים לשלב תחזיות משני המודלים.

אותה טבלה מוצגת גם כגרף. ציר X הוא הפרש ה-ELPD, מדד נראות-החיזוי של כל מודל על תצפיות שהוצאו ממנו, כשערך גבוה יותר אומר חיזוי טוב יותר; כל מודל מקבל שורה משלו על ציר Y. המודל המדורג ראשון, ההיררכי, יושב בדיוק על קו מקווקו אנכי באפס: הוא קו הייחוס שכל שאר המודלים נמדדים ביחסיו. המודל העצמאי מסומן בנקודה על ההפרש שלו, סביב מינוס אחת, עם קו אופקי סביבה שהוא טווח השגיאה התקנית של אותו הפרש, וכיוון שהקו הזה חוצה את קו האפס, ההבדל בין שני המודלים קטן ביחס לרעש שלו, בדיוק כמו שכבר ראינו במספרים בטבלה. וכשהרצתי את ההשוואה, אכן קפצה אזהרה שערך אבחוני מסוים גבוה מדי עבור כמה תצפיות. וכאן קרה דבר מעניין שחייבת לספר עליו: הניחוש הראשוני שלי היה שזה בטח המחוז הענק, כמעט שלושים ותשעה אלף תלמידים, שגורם לבעיה. בדקתי את זה בפועל במקום להסתפק בניחוש, והתברר שהניחוש שגוי לחלוטין: דווקא המחוז הענק קיבל את אחד הציונים הכי טובים, בעוד שרוב שאר המחוזות בקבוצה סומנו כבעייתיים. ההסבר האמיתי: עם רק עשר קבוצות בסך הכל, כל קבוצה בודדת תורמת חלק לא זניח מהראיות לפריור-העל המשותף, כך שהסרת כל קבוצה, גם קטנה, משנה משמעותית את הפרמטרים המשותפים. זו בעיה מוכרת

של השיטה הזאת במודלים היררכיים עם מעט קבוצות, ולא תלויה באיזו קבוצה ספציפית מדובר. הראיתי כאן בדיוק תהליך של בדיקה עצמית: ניחוש סביר, בדיקה בפועל, גילוי שהניחוש שגוי, והסבר טוב יותר על סמך הנתונים.

שאלתי את הצ'אט גם למה בכלל מדברים על "מספר אפקטיבי" של פרמטרים, ולא סופרים אותם ישירות:

Chat, why do we talk about the "effective" number of parameters in WAIC/LOO instead of just counting them?

והוא הסביר שהעונש שמחשבים ב-WAIC וב-LOO מודד כמה כל פרמטר בפועל גמיש כדי להתאים את עצמו לנתונים, ולא כמה פרמטרים יש על הנייר. במודל ההיררכי, אחוזי ההצלחה של המחזות מכווצים חלקית לכיוון הממוצע המשותף ולא חופשיים לגמרי להתאים את עצמם למחוז שלהם, כך שכל אחד תורם בפועל פחות מפרמטר שלם אחד למספר האפקטיבי. המודל ההיררכי יכול להיות בעל יותר פרמטרים על הנייר, כי הוא מוסיף את שני פרמטרי פריור-העל, אבל עם מספר אפקטיבי נמוך יותר מהמודל העצמאי, וזה בדיוק המנגנון שמאפשר לו להכליל טוב יותר. מדדים קלאסיים כמו AIC ו-BIC בנויים למודלים עם מספר פרמטרים חופשיים וקבוע מראש, ולכן אין להם דרך לשקף את הכיווץ הזה, וזאת הסיבה שהם לא הכלי הסטנדרטי להשוואת מודלים בייסאניים היררכיים.

סיכום

לסיכום כל ההשוואות שעברנו עליהן: אומדן נקודה, רווח אמון מול רווח סמך, מבחן השערות מול פקטור בייס, ומודל עצמאי מול היררכי. השורה התחתונה: על המחוז הבודד שבחרנו לדוגמה הראשית, עם מספיק תצפיות, שתי הגישות מגיעות כמעט לאותה תוצאה, אבל ראינו במפורש, בסימולציה על מחוז קטן, באזהרת פקטור בייס, בסיפור המעבר בין המדדים, ובהשוואת שני המחזות, שברגע שהמדגם קטן או שהשאלה מדויקת מספיק, יש הבדלים אמיתיים וניתנים למדידה בין שתי הגישות, ולא רק תיאורטיים.