

תסריט להקלטה למחברת 2: בייסאני מול OLS/ANOVA, טיפים במסעדה

משך משוער: כ-29-34 דקות בהקלטה בפועל (קריאה בקצב בינוני, ללא זמן המתנה על ריצת תאים).

פתיחה

במחברת הזאת אני משווה רגרסיה, פעם בגישה הבייסאנית ופעם בגישה הקלאסית, כדי לבדוק שאלה אחת: האם סכום החשבון במסעדה מנבא את גובה הטיפ, והאם הקשר הזה שונה בין ימות השבוע. הדאטה הוא מאגר אמיתי של 244 חשבונות מסעדה, מובנה בתוך ספריית seaborn. אני משתמשת בכמה מקבילות קלאסיות שונות לאורך המחברת: מול המודל הפשוט אני משווה לרגרסיית OLS רגילה, מול השאלה של הבדלים בין ימים אני משווה גם למבחני ANOVA וגם לקרוסקל-וואליס, ובהמשך, כשבדקת כיווץ מול המודל ההיררכי הבייסאני, אני משווה לרגרסיית OLS נפרדת לכל יום בלי שום שיתוף מידע ביניהם.

הדאטה, ופרדוקס סימפסון

לפני שממשיכים לבניית מודלים, בואו נסתכל רגע על הדאטה עצמו. עוד לפני הגרפים, אני משתמשת בפונקציית describe של פנדס, מפורקת לפי יום, כך שלכל אחד מארבעת הימים מופיעים כמות התצפיות, ממוצע, סטיית תקן, מינימום, מקסימום ואחוזונים, גם של סכום החשבון וגם של הטיפ. אתם יכולים לראות למשל שליום שישי יש רק תשע-עשרה תצפיות שזה הרבה פחות מהימים האחרים שלהם יש בין שישים לשמונים-ושבע תצפיות.

כדי לבדוק חזותית אם קווי הרגרסיה, כל יום בנפרד, הולכים לכיוון שונה מהרגרסיה המאוחדת על כל הימים ביחד, אני בונה את הגרף הזה עם Implot של seaborn, שמצייר אוטומטית קו רגרסיה נפרד לכל יום בשבוע, כל אחד בצבע משלו. סכום החשבון מופיע על ציר ה-X וגובה הטיפ על ציר ה-Y, ומעליהם קו שחור מקווקו שמייצג את הרגרסיה המאוחדת. ואכן אפשר לראות שקווי הרגרסיה הצבעוניים לא לגמרי מקבילים לקו השחור, בעיקר בשיפוע שלהם.

לא הסתפקתי ברושם החזותי הזה, ובדקתי גם באופן מספרי אם יש כאן באמת פרדוקס סימפסון: עם פונקציית polyfit של numpy חישבתי את השיפוע של קו הרגרסיה בנפרד לכל יום, ואת השיפוע של הרגרסיה המאוחדת. כל ארבעת הימים יצאו עם שיפוע חיובי, וגם השיפוע המאוחד יצא חיובי, כך שאין כאן היפוך סימן מלא, וזו לא דוגמה טהורה לפרדוקס סימפסון כמו המקרים הקלאסיים שבהם מגמה שלמה מתהפכת. מה שכן יש הוא הבדל אמיתי בגודל השיפוע בין הימים, כ-0.07 ביום ראשון ועד מעל 0.12 בחמישי, וזו גרסה מתונה יותר של אותה בעיה בדיוק: רגרסיה מאוחדת אחת מטשטשת התנהגות שבפועל שונה בין ימים.

רגרסיה בסיסית: OLS מול בייסאני

ברגרסיה הרגילה יוצאים מנקודת הנחה שהקשר בין גובה הטיפ לסכום החשבון הוא קו ישר, בתוספת איזשהו מקדם שגיאה. המודל שאני בודקת כאן פשוט: הטיפ שווה חיתוך, ועוד שיפוע כפול סכום החשבון, ועוד רעש נורמלי אקראי. באופן שקול אפשר לכתוב שהטיפ עצמו מתפלג נורמלית סביב חיתוך ועוד שיפוע כפול סכום החשבון, וזו הצורה שנראה עוד רגע בקוד ה-PyMC. נתחיל בגרסה הקלאסית: רגרסיית OLS, שאני מריצה עם sm.OLS של סטטסמודלס. שאלתי את הצ'אט מה חשוב לבדוק בפלט הזה:

Chat, what should I look for in this statsmodels OLS output?

והוא ענה שכדאי להסתכל קודם כול על מקדם סכום החשבון, שאומר כמה כל דולר נוסף בחשבון מוסיף בממוצע לטיפ, ולצדו על ערך המובהקות שלו, שבדק אם קשר בגודל כזה יכול לנבוע סתם ממקריות. בנוסף כדאי להסתכל על ה-R-squared, שאומר כמה אחוז מהשונות בטיפ מוסבר על ידי המשתנה הזה לבדו.

הפלט הוא טבלה שלמה, וכדאי לעבור עליה שורה-שורה. ערך ה-R-squared יצא כמעט 46 אחוז, מה שאומר שסכום החשבון לבדו מסביר קרוב למחצית מהשינוי בטיפ, לא הכל, הגיוני, כי טיפ תלוי גם בשירות, בגודל הקבוצה ובמצב הרוח. סטטיסטי F , יחד עם ההסתברות הזעירה שלו, בודק האם המודל כולו משפר את החיזוי בצורה מובהקת לעומת לא להשתמש בשום משתנה, וכאן התשובה ברורה וחד-משמעית.

בשורה של סכום החשבון בטבלת המקדמים יש כמה מספרים שחשוב להבין: המקדם עצמו, קרוב ל-0.105, אומר שכל דולר נוסף בחשבון מוסיף בערך עשרה וחצי סנט לטיפ הצפוי. השגיאה התקנית שלצדו מבטאת את אי-הוודאות סביב האומדן הזה. סטטיסטי ה- t הוא היחס בין השניים, כמה סטיות תקן האומדן רחוק מאפס, ומספר גדול כמו זה שיצא כאן אומר שהקשר בטוח לא אפס במקרה. לצדו יש את ערך המובהקות של אותו מבחן, שיצא זעיר, ולבסוף שני העמודות האחרונות הן רווח הסמך של 95 אחוז למקדם עצמו, שיצא בין כתשעה לשתיים-עשרה סנט בערך. אותו סוג ניתוח קיים גם לחיתוך.

כדאי לבדוק את הנחות OLS בפועל ולא רק להניח שהן מתקיימות, ולכן אני מדפיסה, בעזרת subplots של matplotlib, שלושה גרפי שאריות זה לצד זה. הראשון הוא שאריות המודל מול הערכים המנובאים: פיזור כזה אמור להראות כמו ענן חסר צורה סביב האפס, וכל עקמומיות נראית לעין, צורת משפך, או מגמה, מסמנת הפרת הנחה. השני הוא היסטוגרמה של השאריות, שמראה את צורת ההתפלגות שלהן. השלישי הוא תרשים Q-Q, שמשווה את האחוזונים של השאריות לאחוזונים שהיו מתקבלים מהתפלגות נורמלית מושלמת: נקודות שנצמדו לקו האלכסוני אומרות שהשאריות נראות נורמליות, ועקמומיות שיטתית ממנו, בעיקר בקצוות, אומרת שהן לא.

בפועל, הענן בגרף הראשון מראה נטייה קלה ימינה, ותרשים ה-Q-Q מתעקל בקצה העליון שלו, ושני הסימנים האלה מצביעים על אותה הפרה: השאריות לא באמת נורמליות. כדי לקבל על זה תוצאה פורמלית ולא רק רושם חזותי, הרצתי גם מבחן שפירו-וילק, עם פונקציית shapiro של scipy, שבדק ישירות אם סביר שמדגם נתון הגיע מהתפלגות נורמלית. המבחן יצא עם ערך מובהקות זעיר, כלומר דוחה את ההנחה שהשאריות מתפלגות נורמלית, בדיוק מה שהגרפים כבר רמזו עליו.

שאלתי את הצ'אט מה המשמעות המעשית של זה:

Chat, in practice, what does it mean that the residuals here fail the Shapiro-Wilk normality test, and does it invalidate the regression?

והוא ענה שההפרה מאיימת בעיקר על הדיוק של השגיאות התקניות ורמות המובהקות המדווחות, במיוחד במדגמים קטנים, ולא על האומדן עצמו, שנשאר חסר הטיה כל עוד שאר ההנחות, כמו לינאריות ואי-תלות בין השגיאות, כן מתקיימות. עם 244 תצפיות זה גם משנה פחות משזה נשמע: משפט הגבול המרכזי מבטיח שהתפלגות הדגימה של האומדנים עצמם מתקרבת לנורמלית גם כשהשאריות הגולמיות לא באמת נורמליות, כך שהוא עושה חלק ניכר מהעבודה שהנחת הנורמליות הייתה אמורה לעשות עבור תקפות המבחנים הסטטיסטיים.

עכשיו לאותו מודל בדיוק, בגישה הבייסאנית, ב-PyMC, וצריך לבחור פריור לכל פרמטר לא ידוע במודל, כלומר לכל גודל שאנחנו רוצים לאמוד ולא צופים ישירות בדאטה, במקרה הזה החיתוך, השיפוע, וסיגמא שהיא סטיית התקן של הרעש. פריור הוא ההנחה שלנו, כהתפלגות הסתברות, על הערכים הסבירים של פרמטר כזה עוד לפני שראינו בכלל את הדאטה. לפני שדוגמים בפועל, יש כאן דיאגרמה גרפית של מבנה המודל: סיגמא, החיתוך והשיפוע מופיעים כעגולים פתוחים, כי הם נסתרים ולא ידועים ולכן צריך להם פריור, וכולם מזינים חץ לתוך הטיפ, שמופיע כעגול מוצל כי הוא נצפה, יש לנו את הנתונים בפועל. שאלתי את הצ'אט אילו פריורים כדאי לבחור לפרמטרים האלה ולמה:

Chat, which priors should I choose for the intercept, slope, and sigma here, and why?

והוא ענה שסיגמא, שהיא סטיית התקן של הרעש, חייבת להיות חיובית, ולכן לא ניתן לשים עליה פריור נורמלי רגיל שנותן גם ערכים שליליים, ולכן הציע HalfCauchy עם פרמטר סקאלה 2, התפלגות עם זנב כבד מאוד שכמעט לא מגבילה ערכים גדולים ונותנת לנתונים לדבר בעצמם, ולכן היא הבחירה הסטנדרטית לפרמטרי שונות. לחיתוך ולשיפוע הציע פריור נורמלי רחב, עם ממוצע אפס וסטיית תקן 5, שבעצם אומר "הייתי מופתעת מקשר שגדול מעשרה דולר בערך", מגבלה רחבה מאוד ביחס לטווח האמיתי של טיפים, שנע בערך בין דולר לעשרה דולר, כך שהיא כמעט לא מכתיבה תשובה ורק חוסמת ערכים אבסורדיים. בקוד זה מתורגם ל-pm.HalfCauchy לסיגמא ול-pm.Normal לחיתוך ולשיפוע.

אחרי הדגימה, אני מציגה את הפוסטריורי עם az.plot_dist, בשלושה פאנלים נפרדים, אחד לכל פרמטר (חיתוך, שיפוע וסיגמא). בכל פאנל ציר ה-X הוא הערך האפשרי של הפרמטר וציר ה-Y הוא צפיפות ההסתברות, עם עקומה שמראה כמה סביר כל ערך, וקו אופקי מתחת לעקומה שמסמן את טווח האמון של 95 אחוז, עם נקודה במרכזו שמסמנת את הממוצע והערך המספרי שלו כתובת מעליה. הממוצעים שיצאו כאן: כ-0.92 לחיתוך, כ-0.11 לשיפוע, קרוב מאוד למקדם ה-OLS שכבר ראינו למעלה, וכ-1.0 לסיגמא.

השוואה ישירה בין OLS לבייסאני

עכשיו הרגע המרכזי: עם az.summary אני מוציאה את סיכום הפוסטריורי, והמקדמים והרווחים מוצגים אחד ליד השני, בטבלה ובגרף עם שתי שורות, חיתוך ושיפוע, וכל שורה עם שתי נקודות וקווי שגיאה: נקודה אחת ל-OLS ונקודה שנייה, מתחתיה, לבייסאני. עם כמעט 244 נקודות ופריור כמעט שטוח, השיפוע הבייסאני והשיפוע של OLS יוצאים כמעט זהים ממש, וכך גם רווחי הסמך שלהם. זה לא מקרי: יש תוצאה סטטיסטית ידועה שאומרת שכשיש מספיק דאטה והפריור חלש יחסית לעדות שבנתונים, בדיוק המצב כאן, הפוסטריורי הבייסאני מתכנס לאותו ממוצע ולאותה רמת אי-ודאות כמו האומדן הקלאסי. הערך המוסף של הגישה הבייסאנית כאן הוא לכן לא תשובה שונה למודל הפשוט הזה, אלא הכלים שנבנים סביב הפוסטריורי המלא, שנראה מיד.

מודל חיזוי: רצועות אי-ודאות

הנה דוגמה קונקרטית לאותם כלים, בעזרת pm.sample_posterior_predictive ו-az.hdi. יש כאן גרף חדש שממחיש איך נראית תחזית שכוללת את אי-הוודאות שלה, לא רק ערך בודד כמו שרגרסיה רגילה נותנת, משהו שה-OLS לא נותן ישירות. ציר ה-X הוא סכום החשבון וציר ה-Y הוא הטיפ, ויש כאן שלוש שכבות: קו ברור אחד שמייצג את הממוצע הפוסטריורי של קו הרגרסיה, רצועה צרה יחסית

סביבו שמייצגת רווח אמון על מיקום הקו עצמו, ורצועה הרבה יותר רחבה שמייצגת רווח אמון על תחזית לתצפית חדשה, שכוללת גם את הרעש הרגיל. מתחת לכול, נקודות הפיזור של הדאטה האמיתי. שאלתי את הצ'אט למה הרצועות מתנהגות אחרת זו מזו:

Chat, why do the predictive-interval bands stay roughly constant width while the HDI bands narrow toward the middle of the data?

והוא ענה שהרצועה הפנימית משקפת רק חוסר ודאות על מיקום הקו עצמו, שהכי קטן במרכז הדאטה וגדל בקצוות, בצורת שיעון חול. הרצועה החיצונית מוסיפה על זה עוד מקור אי-ודאות, נפרד לגמרי: גם אם ידענו בדיוק איפה הקו נמצא, טיפ בודד וחדש עדיין לא ייפול בדיוק עליו, כי יש שונות טבעית בין אנשים שהמודל לא מסביר, למשל מצב רוח או איכות השירות, וזה בדיוק מה שסיגמא בקוד מייצגת. אנחנו מניחים שהשונות הזו קבועה לאורך כל טווח סכומי החשבון, וגודלה הרבה יותר גדול מהשינוי הקטן ברוחב הרצועה הפנימית, כך שהיא בולעת אותו כמעט לגמרי ונראית כמעט קבועה.

מה קורה מתחת למכסה המנוע: MCMC ושיטת הרשת

כדי להראות בפועל מה אלגוריתם ה-MCMC עצמו עושה מאחורי הקלעים, ולא רק לדבר על זה תיאורטית, יש כאן גרסה פשוטה יותר של המודל: אותו חיתוך ושיפוע, אבל הפעם עם סיגמא קבועה על אחת ולא פרמטר נלמד, כלומר הטיפ שווה לחיתוך ועוד שיפוע כפול סכום החשבון ועוד רעש נורמלי עם סטיית תקן קבועה של אחת. הסיבה לפשוט היא שעם רק שני פרמטרים חופשיים, חיתוך ושיפוע, אפשר להסתכל ישירות על כל הפוסטריורי המשותף שלהם בשני ממדים על גרף אחד, בלי מימד שלישי של אי-ודאות שהיה מסבך את התמונה. בגרף הפיזור הדו-ממדי של הדגימות, שמצוייר עם `az.plot_pair`, כל נקודה היא דגימה אחת מהשרשרת: ציר ה-X הוא ערכי החיתוך שנדגמו וציר ה-Y הוא ערכי השיפוע שנדגמו. הענן יוצא כרצועה אלכסונית צרה וארוכה, בגלל הקורלציה השלילית החזקה בין החיתוך לשיפוע. שאלתי את הצ'אט למה זה קורה, ואם אפשר לראות את זה בלי MCMC בכלל:

Chat, why does the joint posterior of intercept and slope look like a 2D Gaussian, and is there a way to see this without MCMC?

והוא ענה שעם לייקליהוד נורמלי ופריורים נורמליים, הלוגריתם של הפוסטריורי הוא פונקציה ריבועית של הפרמטרים, וזו בדיוק הצורה המתמטית של גאוסיאן רב-משתני, כך שאין צורך MCMC בכלל כדי לדעת מראש איך התמונה תיראה. בשביל מודל כל כך קטן, עם שני פרמטרים בלבד, אפשר גם להשתמש בשיטת הרשת: מחשבים פריור כפול לייקליהוד על רשת דו-ממדית עדינה של ערכים אפשריים, ומקבלים את אותה תמונה בלי שום דגימה בפועל.

גרף הקונטור הזה הוא כמו מפת גבהים: ציר ה-X הוא ערכי החיתוך על הרשת, ציר ה-Y הוא ערכי השיפוע, וכל קו מתאר מחבר נקודות באותה צפיפות פוסטריורית, ורואים כאן בבירור צורה אליפטית קלאסית. זו אכן אותה התפלגות בדיוק כמו בענן הדגימות למעלה, לא אליפסה אחרת: הקורלציה בין החיתוך לשיפוע כאן חזקה מאוד, קרוב למינוס 0.91, ולכן האליפסה האמיתית צרה ומאורכת מאוד. בענן הדגימות רוב הנקודות נערמות על הציר הארוך שלה ונראות כמו רצועה, ואילו גרף הקונטור מסמן במפורש כמה רמות צפיפות שונות, כולל האזורים הדלילים יותר בשוליים, ולכן חושף את הצורה

האליפטית המלאה. הפעם היא חושבה ישירות בלי שום דגימה. שאלתי את הציאט על נקודה טכנית בקוד עצמו, ולמה שיטת הרשת מוגבלת:

Chat, why is computing the likelihood as a raw product (rather than a sum of logs) problematic here, and why is the grid method only viable for 1-3 parameters?

והוא ענה שעם 244 נקודות, הכפלה ישירה של הסתברויות גולמיות מתאפסת מספרית כמעט מיד, ולכן צריך לעבוד עם לוגריתם ההסתברות ולחבר במקום להכפיל, ורק בסוף להעלות בחזרה בחזקת e . שיטת הרשת עובדת רק עד שניים-שלושה פרמטרים לכל היותר, כי העלות שלה גדלה אקספוננציאלית עם מספר הפרמטרים, היא לא יודעת לאן לכוון מראש בלי לדעת איפה הפוסטריורי בכלל נמצא, וצריך לנחש מראש את טווח הערכים עוד לפני שרואים את הדאטה.

רגרסיה היררכית: מודל בייסאני

עכשיו לשאלה המרכזית של המחברת הזו: האם הקשר בין חשבון לטיפ שונה בין הימים, במיוחד ביום שישי, שיש לו רק תשע-עשרה תצפיות, הרבה פחות מהימים האחרים. בודקת את זה בגישה הבייסאנית, במודל היררכי, בפרמטריזציה ממורכזת: לכל יום יש חיתוך ושיפוע משלו, אבל בניגוד למודל הבסיסי, הם לא מקבלים פריור קבוע ונפרד. במקום זה, ארבעת החיתוכים נשלפים יחד מהתפלגות נורמלית משותפת, וארבעת השיפועים נשלפים יחד מהתפלגות נורמלית משותפת אחרת, כשהממוצע והשונות של כל התפלגות כזו, פריורי-העל, נאמדים בעצמם מהנתונים. בדיאגרמת המודל רואים את זה ישירות: במודל הבסיסי היו רק שלושה עיגולים שמזינים את הטיפ; כאן יש שכבה נוספת מעל החיתוך והשיפוע של כל יום, פריורי-העל שמהם הם נשלפים. זה בדיוק מה שיאפשר ליום עם מעט תצפיות, כמו יום שישי, להישען על המידע מהימים האחרים.

נקודה אחת שכדאי להזכיר מהקוד עצמו: אני ממרכזת את משתנה סכום החשבון לפני בניית המודל, כי סכום החשבון הגולמי רחוק מאוד מאפס, וחיתוך שמוגדר סביבו היה מייצג טיפ צפוי ב"חשבון של אפס דולר", מצב שכמעט לא קיים ופוגע בגיאומטריה של הדגימה. אחרי מירכוז, החיתוך מייצג "טיפ בחשבון בגודל ממוצע", יציב ופרשני הרבה יותר.

אחרי הדגימה, אני מציגה גרף מסלול עם `az.plot_trace`. בגרף יש פאנל נפרד לכל אחד משבעת הפרמטרים של המודל, שני הפריורים-העל המשותפים לכל הימים, החיתוך והשיפוע הספציפיים ליום שישי, שני פרמטרי השונות בין הימים, וסיגמא של הרעש. בכל פאנל ציר ה-X הוא מספר הדגימה, ציר ה-Y הוא הערך שנדגם, וארבעת הצבעים הם ארבע השרשראות, שצריכות להיראות כמו רעש חסר מבנה שחופף כמעט לגמרי. בפועל זה בדיוק מה שרואים בחמישה מתוך שבעת הפאנלים: השרשראות חופפות ברובן, בלי סטייה שיטתית אחת מהשנייה. בשני פרמטרי השונות בין הימים דווקא כן רואים קפיצות בודדות וגבוהות של שרשרת אחת או שתיים מעל שאר הרעש וזהו רמז לבעיית משפך Neal שנבדקת ישירות בהמשך. שאלתי את הציאט אם יש סיבה לדאגה ספציפית לגבי יום שישי, הקבוצה עם הכי מעט תצפיות מכל הימים:

Chat, should I be worried about anything in the trace/summary for the smallest group (Friday, n=19)?

והוא ענה שקבוצה קטנה כמו יום שישי נשענת חזק על הפריורים המשותפים, ולכן שווה לבדוק ספציפית את מדדי ההתכנסות שלה: $\hat{r}$ גבוה מדי או גודל מדגם אפקטיבי נמוך מדי, שני הסימנים

הקלאסיים לקבוצה שקשה לאמוד באופן עצמאי.

בטבלת הסיכום רואים שהרווח סביב השיפוע של יום שישי אכן רחב יותר מזה של הימים האחרים, סימן שאכן יש פחות ודאות סביבו.

משפך Neal

עוד כלי אבחון חשוב, שוב עם `az.plot_pair`, הוא גרף פיזור דו-ממדי: ציר ה-X הוא השיפוע ביום שישי וציר ה-Y הוא פרמטר השונות המשותף, ובו נקודות שסומנו כדיברגנסים, כלומר כישלונות של האלגוריתם, מודגשות בצבע. הן מתרכזות דווקא באזור שבו פרמטר השונות קטן מאוד. שאלתי את הציאת מה אני בעצם רואה כאן, ומה גורם לזה:

Chat, what am I looking for in this pair plot, and what causes it (Neal's funnel)?

והוא ענה שהצורה נקראת משפך כי היא נראית כמו אחד: כשפרמטר השונות המשותף גדול, השיפוע של היום יכול לנוע בטווח רחב סביב הממוצע, כמו הצוואר הרחב של משפך; וכשהוא קטן, השיפוע נכפה להיות קרוב מאוד לממוצע, טווח צר כמו הגרון של המשפך. לקבוצה עם מעט מאוד מידע משלה, כמו יום שישי, השיפוע והפרמטר המשותף נעשים תלויים חזק זה בזה, והפוסטריורי המקומי משתנה בצורה דרסטית בין שני האזורים האלה. גודל צעד קבוע אחד, שהאלגוריתם קובע פעם אחת בתחילת הריצה, פשוט לא יכול להתאים לשניהם גם יחד.

עוד שני כלי אבחון: אוטוקורלציה ו-ESS

שני כלי אבחון נוספים: גרף אוטוקורלציה על פרמטר השונות המשותף, ואחריו גרף גודל מדגם אפקטיבי בגרסה מקומית, עם `az.plot_ess`. שאלתי את הציאת איך בדיוק מחשבים את זה, ולמה יש סף מומלץ של ארבע מאות:

Chat, how does arviz calculate the autocorrelation shown in `az.plot_autocorr`, and why is 400 a common rule-of-thumb target for ESS?

והוא ענה שאוטוקורלציה בפיגור מסוים מודדת כמה דגימה בשרשרת מתואמת עם דגימה שהייתה באותו מרחק פיגור קודם לכן, והציפייה היא שהמתאם יורד מהר לכיוון אפס ככל שהפיגור גדל. גודל מדגם אפקטיבי מודד כמה דגימות בלתי-תלויות שוות ערך יש לנו בפועל, לא כמה דגימות יש על הנייר, כי דגימות עוקבות ב-MCMC תלויות זו בזו מעצם בנייתן. ארבע מאות היא בערך הנקודה שבה שגיאת התקן של מונטה-קרלו על אומדנים סטנדרטיים, כמו ממוצע או אחוזונים, נעשית יציבה מספיק כדי לסמוך עליה.

בגרף האוטוקורלציה ציר X הוא הפיגור וציר Y הוא מידת המתאם, ובגרף ה-ESS המקומי ציר X הוא טווח האחוזונים האפשריים של הפרמטר וציר Y הוא גודל המדגם האפקטיבי הרלוונטי לכל תחום כזה, עם קו מקווקו שמסמן את הסף המומלץ.

בפועל, האוטוקורלציה של פרמטר השונות המשותף יורדת בחדות כבר מהפיגור הראשון, ומסביב לפיגור חמש היא כבר נשארת כמעט תמיד בתוך רצועת חוסר-המובהקות, סימן להתכנסות מהירה וטובה. גרף ה-ESS המקומי, שמוצג כאן לשיפוע של יום שישי, נשאר גבוה בהרבה מקו הסף לאורך רוב הטווח, בסביבות אלפיים עד למעלה משלושת אלפים, מלבד שקיעה חדה וממוקדת ממש סביב האחוזון החמישים, החציון של הפרמטר, שם ה-ESS צונח לכ-400-600, כמעט נוגע בקו הסף. זה לא כישלון, רק

סימן שדווקא סביב הערך המרכזי, איפה שיש הכי הרבה צפיפות אבל גם הכי הרבה חפיפה בין קפיצות ה-MCMC העוקבות, יש מעט פחות דגימות אפקטיביות מאשר בזנבות ההתפלגות.

הפתרון: פרמטריזציה לא-ממוכזת

הפתרון למשפך הוא לשנות איך מייצגים את הפרמטר. רגע כנות שחשוב לספר עליו, כי הוא בדיוק הדגמה של לבדוק תשובה ולא לקחת אותה כמובנת מאליה: הריצה הראשונה שלי, לפני מירכוז ה-X, הראתה בכלל לא שיפור דרמטי, כמעט אותו מספר כישלונות דגימה בשני המודלים. זה היה אמור להדאיג, כי ההסבר של משפך Neal מנבא שיפור גדול. חקרתי את זה במקום להתעלם, ומצאתי בעיה נפרדת ומקבילה: לא מירכזתי את משתנה ה-X עצמו, מה שיוצר בדיוק את בעיית הקורלציה המלאכותית בין החיתוך לשיפוע שהזכרתי קודם, והיא פוגעת בשני המודלים באותה מידה, ובכך מסתירה את התועלת האמיתית של תיקון המשפך. אחרי שמירכזתי את ה-X, קיבלתי את התוצאה האמיתית: מהמודל הממוכז לבדו, עם כ-463 כישלונות דגימה, למודל הלא-ממוכז, עם 10 בלבד, שיפור דרמטי ואמיתי, בדיוק כמו שהתאוריה חוזה. שאלתי את הצ'אט מה בדיוק ההבדל מהמודל הממוכז:

Chat, what's the difference between this model and the centered one?

והוא ענה שבמקום להצהיר על השיפוע של כל יום ישירות כנשלף מהתפלגות משותפת, מצהירים על משתנה סטנדרטי בסקאלה קבועה, ובונים את השיפוע בפועל כפעולה דטרמיניסטית: ממוצע משותף, ועוד המשתנה הסטנדרטי כפול סטיית התקן המשותפת. זה בעצם מנתק את הגיאומטריה שה-NUTS צריך לחקור: למשתנה הסטנדרטי יש פוסטריורי קבוע ומתנהג יפה בסקאלת יחידה, בלי קשר לכמה קטנה סטיית התקן המשותפת נעשית, והגיאומטריה הבעייתית של המשפך עוברת לתוך כפל דטרמיניסטי פשוט במקום להישאר בתוך הפרמטר הנדגם עצמו.

כיווץ: רגרסיה נפרדת מול בייסאני היררכי

עכשיו לבדוק את הכיווץ. השאלה היא אם משווים שיפוע נפרד לכל יום, שמותאם ב-OLS בלי שום שיתוף מידע בין הימים, מול הממוצע הפוסטריורי הבייסאני, שכן משתף מידע בין הימים דרך הפריור-העל, לאיזה כיוון ובאיזו עוצמה זו כל יום, ומה מסביר את זה. שאלתי את הצ'אט את זה במפורש:

Chat, compare the day-level slope estimates from: (a) fitting each day completely separately with its own OLS, and (b) the Bayesian hierarchical posterior mean. Which days move the most, and why?

הצ'אט לא ענה במילים הפעם, אלא הציע קוד שבונה טבלת השוואה בין שני השיפועים לכל יום, ביחד עם גרף שממחיש אותה. כשהרצתי את זה, התוצאה לא הייתה זו שציפיתי לה: יום ראשון, לא יום שישי, זו הכי הרבה, מכ-0.070 לכ-0.079. יום שישי, שהוא דווקא הקבוצה הכי קטנה עם רק תשע-עשרה תצפיות, זו הכי פחות מכל הימים, מכ-0.095 לכ-0.100 בלבד. שאלתי את הצ'אט למה זה קורה, לאור זה שציפיתי שדווקא הקבוצה הכי קטנה תיכווץ הכי הרבה:

Chat, why does Sunday shrink the most here instead of Friday, the smallest group?

והוא ענה שהכיוון מושך כל יום לכיוון הדפוס המשותף של ארבעת הימים ביחד, וכמה כל יום זז בפועל תלוי קודם כול במרחק ההתחלתי של האומדן הנפרד שלו מהדפוס הזה, לא רק בגודל המדגם שלו. האומדן הנפרד של יום ראשון יצא נמוך במיוחד ביחס לשלושת הימים האחרים, ולכן דווקא הוא נמשך הכי הרבה, למרות שיש לו שבעים ושש תצפיות, הרבה יותר מיום שישי. האומדן הנפרד של יום שישי, לעומת זאת, יצא כבר קרוב למדי לדפוס המשותף מלכתחילה, כך שלמודל אין הרבה מה לתקן שם, גם אם התאוריה אומרת שקבוצה כל כך קטנה אמורה להיות הרגישה ביותר לכיוון. גודל מדגם קטן קובע כמה חזק המודל יכול למשוך קבוצה לכיוון הממוצע, אבל לא בהכרח כמה הוא בסוף בפועל מזיז אותה.

הגרף כאן, עם שני טורים, ללא שיתוף ובייסאני, וקו לכל יום שמחבר בין שתי הנקודות שלו, מאמת את זה חזותית: הקו של יום ראשון הוא בעל השיפוע התלול ביותר בין שני הטורים, ואילו הקו של יום שישי כמעט אופקי.

שאלה פשוטה יותר: משתי ימים לארבעה

כל מה שראינו עד עכשיו משווה את הקשר בין חשבון לטיפ, כלומר את השיפוע, בין הימים. שאלה פשוטה יותר, וקלאסית יותר, שמתעלמת מגודל החשבון לגמרי: האם אנשים פשוט משאירים סכומי טיפ שונים בימים שונים? נקודת המוצא הטבעית, לפני שמשווים את כל ארבעת הימים ביחד, היא המקרה הפשוט של שתי קבוצות: האם סכומי הטיפ הגולמיים בשבת ובשישי שונים זה מזה? שאלתי את הצ'אט מה צריך לבדוק לפני שמריצים מבחן t , ומה האלטרנטיבה הלא-פרמטרית לו אם ההנחות לא מתקיימות:

Chat, what do I need to check before running a t-test, and what's the non-parametric alternative?

והוא ענה שלפני מבחן t בלתי-תלוי לשתי קבוצות, כדאי לבדוק שכל קבוצה קרובה יחסית להתפלגות נורמלית, ושהשונויות של שתי הקבוצות דומות זו לזו. יש גרסה מתוקנת למקרה של שונויות לא שוות, שנחשבת ברירת מחדל בטוחה יותר כשלא בטוחים. כשאלה נראות בעייתיות, כפי שכבר ראינו קודם בבדיקת הנורמליות של השאריות, האלטרנטיבה הלא-פרמטרית היא מבחן מן-וויטני, שמשווה בין שתי הקבוצות רק לפי הדירוגים של הנתונים המאוחדים ולא לפי הערכים הגולמיים.

הרצתי את שני המבחנים, עם `ttest_ind` ו-`mannwhitneyu` של `scipy`, על סכומי הטיפ בשבת ובשישי, ושניהם הגיעו לאותה מסקנה איכותית: אין הבדל מובהק בין שני הימים האלה בטיפ הגולמי. זה מרגיע, אבל זה לא תמיד יהיה כך, וההשוואה הרחבה יותר בהמשך היא בדיוק המקום שבו כבר ראינו את התשובה הפרמטרית והלא-פרמטרית נפרדות זו מזו.

עכשיו לכל ארבעת הימים ביחד. שאלתי את הצ'אט מה השערת האפס של ANOVA, ולמה זה בעצם "רק" מבחן F :

Chat, what's H_0 of a one-way ANOVA, what are its assumptions, and why is it "just" an F-test?

והוא ענה שהשערת האפס היא שלכל הקבוצות אותו ממוצע אוכלוסייתי. ANOVA עובד על ידי השוואת השונות בין ממוצעי הקבוצות לשונות בתוך הקבוצות, והיחס הזה מתפלג לפי התפלגות F תחת השערת האפס, כך ש-ANOVA ומבחן F חד-כיווני הם אותו הליך בדיוק תחת שני שמות שונים.

קורסים שלמים קיימים על ANOVA בעיקר בגלל איך זה מוכלל לכמה גורמים ואינטראקציות, לא כי המקרה החד-כיווני עמוק יותר ממבחן F. ההנחות שלו דומות להנחות של OLS: תצפיות בלתי-תלויות, שאריות מתפלגות נורמלית בתוך כל קבוצה, ושונות שווה בין הקבוצות, ומבחן בארטלט הוא הבדיקה הקלאסית הסטנדרטית לזה האחרון.

הרצתי את מבחן בארטלט, עם bartlett של scipy, על סכומי הטיפ בארבעת הימים, ותוצאתו הייתה מובהקת: השונות באמת לא שוות: יום שבת מפוזר משמעותית יותר מיום שישי. זו בדיוק ההנחה ש-ANOVA נשען עליה, וכאן היא מופרת לא רק בתיאוריה אלא בנתונים עצמם. הרצתי בכל זאת את ה-ANOVA עצמו, עם f_oneway, ויצא לא מובהק. שאלתי את הציאט מתי בכלל עדיף להעדיף את המבחן הלא-פרמטרי המקביל:

Chat, when should I prefer Kruskal-Wallis over ANOVA, and does it matter here?

והוא ענה שקרוסקל-וואליס בודק אם המדגמים מגיעים מאותה התפלגות באמצעות הדירוגים בלבד של הנתונים המאוחדים, ולא הערכים הגולמיים, ולכן הוא לא דורש נורמליות והרבה פחות רגיש להפרת שוויון השונות. זה הגיבוי הטבעי בדיוק כשההנחות של ANOVA נראות רופפות, כמו שראינו במבחן בארטלט.

וכן, זה משנה כאן בפועל: ANOVA חוזר לא מובהק, בעוד קרוסקל-וואליס על אותם נתונים בדיוק חוזר מובהק. אי ההתאמה הזו בין שני המבחנים חשובה, ולא כדאי סתם לבחור את המספר הנוח. מכיוון שמבחן בארטלט כבר אמר לנו שההנחה של ה-ANOVA עצמו מופרת, התשובה האמינה יותר כאן היא זו של קרוסקל-וואליס: על סכום הטיפ הגולמי, ארבעת הימים כנראה כן שונים במידה מסוימת, רק לא בצורה שמבחן רגיש-לשונות עם הנחה שלא מתקיימת יכול לזהות באמינות. זו סיבה אמיתית וניתנת לבדיקה להעדיף את המסקנה של מבחן אחד על פני אחר, על אותם נתונים בדיוק, לא רק הסתייגות תיאורטית.

לשאלה המקורית, לא הפשוטה, יש כבר תשובה בייסאנית מוכנה בלי מודל נוסף: מהפוסטרירי המלא של השיפוע לכל יום, שכבר בנינו, אפשר לקרוא הבדל בין שתי קבוצות ישירות מההפרש ביניהן, בלי לבחור בין מבחנים מתחרים ובלי לדאוג איזה מהם עומד בהנחותיו. בדקתי עם az.hdi את ההפרש בין שיפוע חמישי לשיפוע ראשון, הזוג עם ההבדל הגדול ביותר בטבלת הסיכום. רווח האמון של 95 אחוז יוצא בקושי חיובי לגמרי, וההסתברות הפוסטרירית ששיפוע חמישי גדול משיפוע ראשון קרובה לתשעים ושמונה אחוז: עדות אמיתית וסבירה, אבל לא מוחלטת. יש כאן הבדל אמיתי בקשר חשבון-טיפ בין שני הימים האלה, רק לא הבדל מוחץ.

סיכום

לאורך המחברת הזו השוינו גישה בייסאנית מול גישה קלאסית על אותה שאלה בדיוק: האם סכום החשבון מנבא את גובה הטיפ, והאם הקשר הזה שונה בין ימים. שלושה ממצאים עיקריים עולים מזה. ברגסיה הבסיסית, OLS והבייסאני יצאו כמעט זהים, וההבדל האמיתי בין הגישות לא היה בתשובה עצמה אלא בכלים הנוספים שהפוסטרירי המלא מאפשר, כמו רצועות אי-ודאות. במודל ההיררכי ראינו שכיווץ לא בהכרח פוגע הכי חזק בקבוצה הקטנה ביותר, אלא בקבוצה שהאומדן הנפרד שלה התחיל הכי רחוק מהדפוס המשותף. ובשאלת ההבדל בין ימים, ANOVA וקרוסקל-וואליס נתנו תשובות סותרות זו לזו, בעוד שהגישה הבייסאנית נתנה תשובה ישירה בלי צורך לבחור מבחן מראש.

שווה גם לזכור: רק במודל הבייסאני, שדוגם מהפוסטריורי, הייתה בכלל בעיית דגימה כמו משפך Neal, וגם מצאנו לה פתרון.