

תסריט להקלטה למחברת 3: ניתוח שרידות, חולי סרטן ריאות

משך משוער: כ-17-19 דקות בהקלטה בפועל (קריאה בקצב בינוני, ללא זמן המתנה על ריצת תאים).

פתיחה

המחברת הזאת עוסקת בניתוח שרידות, כלומר כמה זמן שורדים ומה מנבא את זה. הדאטה הוא מאגר אמיתי של 228 חולי סרטן ריאות מתקדם, מתוך מחקר קליני אמיתי, שמגיע מובנה בתוך חבילת lifelines בפייתון. לכל חולה יש שדה זמן, שהוא מספר הימים ממעקב ועד מוות או עד הקשר האחרון איתו, ושדה סטטוס: אחת אם המוות נצפה בפועל, ואפס אם החולה עדיין היה בחיים כשהמחקר הסתיים או שאיבדו איתו קשר. המקרה השני נקרא צנזורה מימין: אנחנו יודעים שהחולה שרד לפחות עד אז, לא בדיוק כמה זמן מעבר לזה. זה בדיוק העניין המרכזי בניתוח שרידות: איך משתמשים נכון גם בחולים שראינו את המוות שלהם וגם בחולים שלא.

לצד lifelines עצמה, נטענת גם הפונקציה שמציירת ציר-זמן לכל חולה, ומבחן הלוג-ראנק שנשתמש בו בהמשך להשוואת קבוצות.

לפני שממשיכים, כדאי להגדיר פעם אחת כמו שצריך מושג יסוד שחוזר לאורך כל המחברת: מהו שיעור סיכון. זו לא ההסתברות למות בכלל, אלא ההסתברות הרגעית למות ברגע הבא ממש, בהינתן שהחולה כבר שרד עד עכשיו. אם חולה שרד עד יום 300, שיעור הסיכון ביום 300 אומר כמה מסוכן המצב שלו עכשיו, מותנה בכך שהוא כבר החזיק מעמד עד לכאן, וזה שונה מהותית מהשאלה "מה הסיכוי שימות אי-פעם", ששווה מאה אחוז לכולם בסוף. כל המודלים שנראה במחברת הזאת הם בעצם דרכים שונות להניח או לאמוד איך שיעור הסיכון הזה מתנהג עם הזמן: קבוע? עולה? יורד? תלוי בגיל ובמצב הרפואי של החולה?

הצגת הדאטה

בואו נסתכל על הדאטה עצמו לפני שממשיכים. יש לעמודת הצריכה הקלורית ערכים חסרים לכמעט עשרים ואחד אחוז מהחולים, והייתי צריכה להחליט מה עושים עם זה: האם להשלים את הערכים החסרים, או פשוט להוציא את העמודה מהניתוח. שאלתי את הצי'אט:

Chat, meal.cal is missing for 47 of 228 patients (~21%) — should I impute it or drop it?

והוא ענה שעם כמות חוסר כזאת, ובלי סיבה טובה להניח שהחוסר אקראי לגמרי (חולים חולים יותר אולי פחות ימלאו שאלון תזונה), השלמה מהירה מסתכנת בהטיה שקטה. הבחירה הפשוטה והבטוחה היא להוציא את העמודה הזו מהמשתנים שנבדוק, ולציין את זה בגלוי.

בגרף הזה, שמצויר עם plot_lifetimes של lifelines, יש קו אופקי לכל אחד מעשרים וחמישה חולים אקראיים: ציר ה-X מייצג ימים ממועד הכניסה למחקר, וציר ה-Y מייצג חולה בודד בכל שורה, מתחילת המעקב שלו ועד סופו. קו שמסתיים בנקודה מלאה מייצג מוות שנצפה, קו שנשאר פתוח מייצג צנזורה. לצדו שני גרפי violin, עם violinplot של seaborn, שמראים את התפלגות זמן ההישרדות, פעם לפי מין ופעם לפי סטטוס.

יש בגרף הזה ערכים שליליים למרות שזמן הישרדות תמיד חיובי, וזה נראה מוזר, אז שאלתי את הצי'אט מה קורה שם:

Chat, I get negative values in this violin plot even though survival time is strictly positive — what gives?

והוא ענה שזה קורה כי שיטת הציור מחליקה את הצורה של ה-violin בעזרת אומדן צפיפות שלא "יודע" שהזמן חסום מלמטה, ולכן מורח קצת צפיפות מעבר לאפס. זה ארטיפקט חזותי בלבד, לא טענה על נתונים שליליים.

לא הסתפקתי בתשובה המילולית, ובדקתי ישירות בקוד מה המינימום בפועל בעמודת הזמן, ואכן יצא חמישה ימים, חיובי לגמרי.

ברירת המחדל: זמן מתפלג אקספוננציאלית

עכשיו לשלב הראשון של המידול עצמו: שאלתי את הציאט למה בכלל מתחילים מהתפלגות אקספוננציאלית לזמן עד אירוע, ולמה היא עלולה להיות לא מתאימה כאן:

Chat, why is the exponential distribution the traditional default for time-to-event data, and why might it be a poor fit for lung cancer survival specifically?

והוא ענה שהיא ההתפלגות הרציפה היחידה עם שיעור סיכון קבוע לגמרי, תכונה שנקראת חוסר זיכרון, שבה הסיכוי למות ברגע הבא לא תלוי כמה זמן כבר שרדת. זו הנחת מוצא טבעית כשלא יודעים כלום נוסף. אבל היא התאמה גרועה למחלה מתקדמת כמו סרטן ריאות, כי הסיכון בדרך כלל עולה ככל שהזמן ממועד האבחון חולף, וזה בדיוק מה שהתפלגות ויבול, בזכות פרמטר הצורה שלה, יכולה לתפוס, בעוד שההתפלגות האקספוננציאלית לא יכולה.

הפונקציה הסטנדרטית שמתאימה התפלגות אקספוננציאלית לנתונים, כמו `expon.fit` של `scipy`, היא כלי התאמת נראות מרבית: בדיוק כמו `p_hat` שראינו במחברת הראשונה, היא מוצאת את הפרמטר שהופך את הנתונים שבאמת ראינו לסבירים ביותר. הבעיה כאן היא לא בעיקרון עצמו, אלא בכך שהפונקציה הזו לא מכירה כלל את המושג צנזורה: אם נותנים לה את כל עמודת הזמן כמות שהיא, היא מתייחסת לכל חולה מצונזר כאילו מת בדיוק ביום שבו הפסיקו לעקוב אחריו. הגרסה שמתחשבת בצנזורה כמו שצריך היא `ExponentialFitter` של `lifelines`.

לא הסתפקתי בטענה הזו, ובדקתי כמה זה עולה לנו במספרים: התאמה נאיבית כזאת נותנת תוחלת הישרדות של כ-305 ימים, בעוד שהתאמה נכונה, שמתחשבת בצנזורה כמו שצריך, נותנת כ-422 ימים. ההתעלמות מצנזורה מקטינה כאן את תוחלת ההישרדות המוערכת בכ-28 אחוז: הטיה ממשית וגדולה, לא הערת אגב תיאורטית.

התאמת ויבול הנכונה

התאמת ויבול הנכונה, עם `WeibullFitter` של `lifelines`, שמתחשבת בצנזורה, נותנת פרמטר צורה של כ-1.32 ופרמטר סקאלה של כ-418. הגרף שמשווה את שתי ההתאמות: ציר ה-X הוא ימים, ציר ה-Y הוא צפיפות הסתברות, היסטוגרמה שקופה ברקע של זמני המוות שבאמת נצפו, ומעליה שתי עקומות, האקספוננציאלית והוויבול, ששתייהן הפעם מותאמות כמו שצריך עם התחשבות בצנזורה. שאלתי את הציאט מה זה אומר לנו בפועל:

Chat, what does the fitted Weibull shape parameter ($\rho \approx 1.32$) tell us here?

והוא ענה שפרמטר צורה ששווה בדיוק אחת היה מצמצם את ויבול בחזרה להתפלגות האקספוננציאלית, עם שיעור סיכון קבוע; פרמטר גדול מאחת אומר שהסיכון עולה עם הזמן, בדיוק כמו שהסיפור של מחלה מתקדמת מנבא. חשוב לדייק: 1.32 היא עלייה מתונה, לא דרמטית, וערך סביב שלוש עד חמש היה מצביע על עלייה הרבה יותר חדה בסיכון.

אמידה לא-פרמטרית: הטעות הנאיבית השנייה, ותיקון קפלן-מאייר

יש גם דרך לגמרי אחרת להעריך שרידות, בלי להניח שום צורת התפלגות מראש: פשוט אחד פחות הפונקציה המצטברת האמפירית של הזמנים, עם `ecdf` של `scipy`. שני גרפים זה לצד זה: בשמאלי ציר ה-X ימים וציר ה-Y ההסתברות המצטברת שכבר מת עד אותו יום, עולה במדרגות מאפס לאחת; בימני בדיוק ההפך, אחד פחות זה, פונקציית השרידות הנאיבית, יורדת במדרגות מאחת לאפס. אבל יש כאן פיתוי נאיבי נוסף, שונה מהקודם: להתייחס לכל חולה מצונזר כאילו "נכשל" בדיוק ברגע הצנזורה שלו. שאלתי את הצ'אט מה הבעיה בזה, ומה הפתרון:

Chat, what's wrong with the naive estimator "1 - ECDF" once censoring is present, and what's the fix?

והוא ענה שזה מייצר מוות שמעולם לא נצפה בפועל: חולה שהיה בחיים ובריא ביום החמש-מאות כשהמחקר פשוט הסתיים נספר כאילו מת אז. זה מטה את ההערכה כלפי מטה, וההטיה מצטברת ככל שעובר זמן, בדיוק במקום שבו יש הכי הרבה צנזורה. הפתרון הוא אומדן קפלן-מאייר, עם `KaplanMeierFitter` של `lifelines`, שבכל נקודת זמן של מוות בפועל משתמש רק בחולים שעדיין נמצאים בסיכון (בחיים ולא מצונזרים עדיין), ומכפיל הסתברויות שרידות מותנות זו בזו. חולה מצונזר תורם מידע עד לרגע הצנזורה שלו, ואז פשוט יוצא מקבוצת הסיכון בלי שנרשם לו מוות.

שווה לשים לב: זו למעשה אותו כיוון הטיה כמו הטעות הקודמת, לא הפוך ממנה: שם ההטיה הייתה כלפי מטה בתוחלת ההישרדות המוערכת (כ-28 אחוז פחות מהאמת), וכאן היא כלפי מטה בהסתברות ההישרדות עצמה. שני קיצורי דרך שונים לגמרי מבחינת המנגנון, על שני מדדים שונים, אבל שניהם ממעיטים בהישרדות ולא מגזימים בה, ושווה לזכור את זה במקום ללמוד כלל אצבע כללי מדי. עקומת קפלן-מאייר עצמה: ציר ה-X הוא ימים, ציר ה-Y הוא הסתברות שרידות בין אפס לאחת, והקו יורד במדרגות בכל נקודת מוות.

רווחי סמך סביב העקומה

יש עוד נקודה טכנית שכדאי להבין לפני שממשיכים: שאלתי את הצ'אט איך `lifelines` בכלל מחשבת את רצועת הביטחון סביב עקומת קפלן-מאייר, ולמה משתמשים בטרנספורמציה של לוג-לוג:

Chat, how does `lifelines` compute the confidence band around the KM curve, and why does it use a $\log(-\log(x))$ transform?

והוא ענה שהשונויות מחושבת בנוסחת גרינווד, שהיא סכום על פני כל זמני המוות הקודמים. הבעיה עם רווח סמך סימטרי רגיל, שנבנה ישירות על ההסתברות: הוא עלול לצאת מחוץ לטווח שבין אפס לאחת, בדיוק במקומות שבהם העקומה כבר קרובה לאפס או לאחת. הטרנספורמציה ממפה את הטווח שבין אפס לאחת לכל הישר הממשי, כך שבונים רווח סימטרי בסקאלה הזאת ומחזירים אותו בחזרה, וכך הוא מובטח להישאר בתוך הגבולות הנכונים.

הגרף הזה ממחיש בדיוק את הטרנספורמציה: ציר ה-X הוא ההסתברות המקורית, ציר ה-Y הוא הערך אחריה, ורואים עקומה שעולה בתלילות בקצוות ומתונה באמצע.

סיכון מצטבר: נלסון-אאלן

עוד מדד שימושי, שקשור ישירות לעקומת קפלן-מאייר: הסיכון המצטבר. הגרף שלו: ציר ה-X ימים, ציר ה-Y סיכון מצטבר, וקו שעולה במדרגות, כיוון הפוך מקפלן-מאייר, שיורד. שאלתי את הציאט למה לא פשוט לקחת מינוס לוגריתם של קפלן-מאייר כדי לקבל אותו, במקום לבנות אומדן נפרד:

Chat, why not just estimate the cumulative hazard as $-\log(\text{KM survival})$ instead of using a separate Nelson-Aalen estimator?

והוא ענה שפונקציית מינוס-לוגריתם קמורה, ולפי אי-שוויון ינסן הציפייה שלה תמיד גדולה או שווה למינוס-לוגריתם של הציפייה, כך שהקיצור הזה מטה כלפי מעלה את הסיכון המצטבר המוערך. אומדן נלסון-אאלן, עם NelsonAalenFitter של lifelines, מחשב את הסיכון המצטבר ישירות מהנתונים ונמנע מהבעיה מהמקור.

השוואת קבוצות: מין, ומבחן לוג-ראנק

עכשיו להשוואה בין קבוצות. שתי עקומות קפלן-מאייר על אותו גרף, גברים מול נשים בצבעים שונים, מראות הבדל חזותי ברור: עקומת הנשים נשארת גבוהה יותר לאורך כל התקופה. זה נראה שונה, אבל שאלתי את הציאט איך בודקים אם ההבדל הזה משמעותי סטטיסטית ולא רק רושם חזותי:

Chat, the two curves look different — how do I test whether that's statistically meaningful, and what should I do next if it is?

והוא ענה שהכלי הסטנדרטי הוא מבחן לוג-ראנק: הוא משווה בכל נקודת זמן כמה מקרי מוות נצפו בכל קבוצה מול כמה היו צפויים תחת ההנחה שלשתי הקבוצות אותו סיכון, ומצרף את ההפרשים האלה לכדי סטטיסטי חי-בריבוע יחיד לאורך כל התקופה. אם התוצאה מובהקת, הצעד הטבעי הבא הוא רגרסיית קוקס, שמאפשרת לכמת את גודל ההבדל ולבקר על משתנים נוספים בו-זמנית. הרצתי את המבחן בפועל, עם logrank_test של lifelines, וקיבלתי סטטיסטי מבחן של 10.33 עם ערך p קטן מ-0.005: הבדל מובהק בין המינים, לא רק רושם.

רגרסיית קוקס

עד כה השוונו רק שתי קבוצות בבת אחת. כדי לבקר על כמה משתנים יחד, צריך מודל רגרסיה מלא: רגרסיית קוקס, עם CoxPHFitter של lifelines. שאלתי את הציאט להסביר מה זה בכלל מודל "חצי-פרמטרי", ולמה אין במודל הזה איבר חיתוך בכלל:

Chat, explain the Cox model: what does "semi-parametric" mean here, and why is there no intercept?

והוא ענה שמודל קוקס כותב את הסיכון כפונקציית סיכון בסיס משותפת לכולם, לא-פרמטרית, כפול גורם הכפלה פרמטרי שתלוי במשתנים של כל חולה, וזה בדיוק מקור השם "חצי-פרמטרי". הטריק שמאפשר להתאים את המודל בלי לפרט בכלל את פונקציית הסיכון הבסיסית נקרא נראות חלקית: בכל רגע מוות שואלים רק מבין כל מי שעדיין בסיכון עכשיו, מה ההסתברות שדווקא זה שבאמת מת

הוא זה שמת, ופונקציית הסיכון המשותפת מצטמצמת החוצה מהיחס הזה לגמרי. אין חיתוך במודל כי הוא היה רק מכפיל את פונקציית הסיכון הבסיסית בקבוע, ופונקציית הסיכון הבסיסית, שחופשית להיות כל צורה שהיא, כבר סופגת את זה: חיתוך כאן פשוט לא ניתן לזיהוי בנפרד.

אני משתמשת בגיל, מין, ניקוד תפקוד יומיומי (ph.ecog, בסולם מאפס עד ארבע), וירידה במשקל כמשתני חיזוי: ארבעה גורמים קליניים מובחנים זה מזה. בדאטה יש גם שני ניקודי תפקוד נוספים שדומים מאוד ל-ph.ecog, ולכן לא נכללו, כדי לא לכפול את אותו מידע פעמיים. נשארים 213 מתוך 228 חולים עם נתונים מלאים על ארבעת המשתנים שנבחרו.

בטבלת הפלט יש כמה חלקים שכדאי לפרק. למעלה מופיע ערך הנראות החלקית, ומבחן יחס-נראות שמשווה את המודל המלא, עם כל ארבעת המשתנים, מול מודל ריק בלי אף משתנה, ובודק אם כל המודל יחד משפר את ההתאמה באופן מובהק, ולא רק כל משתנה בנפרד. שאלתי את הצ'אט איך קוראים את הפלט הזה בפועל:

Chat, explain this lifelines output — which covariates matter, and how do I read the hazard ratios ($\exp(\text{coef})$)?

והוא ענה שכל מקדם הוא הלוגריתם של יחס הסיכון, ולצדו יחס הסיכון עצמו: כמה כל עלייה של יחידה אחת במשתנה מכפילה את הסיכון כשכל השאר קבוע, כשמעל אחת זה סיכון גבוה יותר ומתחת לאחת זה מגן. מדד ההתאמה של המודל מודד באיזה שיעור מכל הזוגות האפשריים של חולים המודל מדרג נכון מי מת קודם: 0.5 שווה להטלת מטבע, 1.0 שווה לדירוג מושלם.

בפועל: היות אישה יצא קשור לסיכון נמוך בכ-45 אחוז בכל רגע נתון, בהתאמה מלאה לתוצאת מבחן הלוג-ראנק. ניקוד התפקוד היומיומי יצא עם יחס סיכון של כ-1.67 ועם מובהקות גבוהה: ניקוד גרוע יותר מנבא סיכון גבוה משמעותית יותר, בדיוק כמו האינטואיציה הקלינית. גיל וירידה במשקל יצאו עם יחס סיכון קרוב מאוד לאחת ובלי מובהקות, כלומר במודל הזה, עם שאר המשתנים כבר בפנים, הם לא תרמו מידע נוסף משמעותי. ומדד ההתאמה עצמו יצא 0.65, סביר לדאטה קליני עם רק כמה משתנים, אבל לא מושלם.

איך מציירים בכלל עקומת שרידות מתוך מודל קוקס

בגרף הזה, עם `plot_partial_effects_on_outcome` של lifelines, יש שתי עקומות שרידות זו לצד זו, לגברים ולנשים: ציר ה-X מייצג ימים, וציר ה-Y מייצג הסתברות שרידות משוערת. שאר המשתנים קבועים במוצג שלהם עבור שתי העקומות, כך שההבדל היחיד ביניהן הוא המין. רואים חזותית בדיוק את אותו פער שכבר ראינו במבחן לוג-ראנק, רק שהפעם עם שאר המשתנים מבוקרים.

שאלתי את הצ'אט שאלה שהטרידה אותי: אם מודל קוקס אף פעם לא אמד את פונקציית הסיכון הבסיסית במפורש, איך בכלל הצליחו לצייר ממנו עקומת שרידות קונקרטית כמו זו?

Chat, the Cox model never specified a baseline hazard function, so how can lifelines draw an actual survival curve here?

והוא ענה שזה קורה דרך אומדן ברסלו: אחרי שיש לנו את המקדמים מהנראות החלקית, אומדים את הסיכון המצטבר הבסיסי בצורה לא-פרמטרית מאותם נתונים, ואז משלבים אותו עם כל פרופיל משתנים שרוצים, כדי לקבל עקומה קונקרטית וניתנת לציור.

הנחת הסיכונים הפרופורציונליים אומרת שההשפעה של כל משתנה על הסיכון קבועה לאורך זמן ולא משתנה. בודקת את זה עם `check_assumptions` של `lifelines`. שאלתי את הצ'אט מה הכלי שבודק את זה, ומה הוא בעצם מראה:

Chat, what are scaled Schoenfeld residuals, and what does this check tell me?

והוא ענה שלכל מוות שנצפה, שאריות שנפלד מותאמות מודדות כמה הערך של אותו משתנה סטה ממה שהמודל ציפה באותו רגע ספציפי בזמן, ומגמה כלפי הזמן בגרף השאריות האלה היא הסימן המובהק להפרת ההנחה.

יש כאן ארבעה גרפים נפרדים, אחד לכל משתנה חיצוני, גיל, מין, ניקוד תפקוד וירידה במשקל: בכל גרף ציר ה-X הוא ציר הזמן אחרי טרנספורמציה (זמן מדורג), ציר ה-Y הוא השארית המותאמת של אותו משתנה, נקודה לכל מוות שנצפה, ועליהן קו החלקה שחור, ומסביבו כמה קווים אפורים דקים שמייצגים דגימות בוטסטראפ שונות במקום רצועת ביטחון אחידה. קו שטוח וקרוב לאפס לאורך כל הציר אומר שההשפעה של המשתנה אכן קבועה בזמן; מגמה ברורה בקו החלקה, עולה או יורדת, הייתה הסימן להפרה. בפועל, הבדיקה שהרצתי החזירה שההנחה נראית תקינה בכל ארבעת המשתנים, ואין עדות להפרה משמעותית באף אחד מהם.

סיכום

לסיכום, עברנו על מלוא מסלול הכלים: התאמה פרמטרית עם ובלי צנזורה, כאשר ההטיה של ההתעלמות מצנזורה נמדדה במפורש ולא רק נטענה; הפונקציה המצטברת האמפירית הנאיבית מול קפלן-מאייר; נלסון-אאלן לסיכון מצטבר; מבחן לוג-ראנק; ורגרסיית קוקס מלאה עם בדיקת הנחות. הכול על נתוני מעקב אמיתיים של חולי סרטן ריאות, עם שתי הטיות שונות במנגנון שלהן אבל שתיהן ממעיטות בהישרדות, שנמדדו במספרים ולא רק נטענו.